

PROPOSAL PENELITIAN

Program Studi D-IV Komputasi Statistik

Sekolah Tinggi Ilmu Statistik (STIS)

**Analisis Transformasi Tutupan Lahan Spatiotemporal di
Kalimantan**

**Tahun 2018–2024 Menggunakan Sentinel-2 dan Machine
Learning**

**untuk Mengkaji Dampak Dual-Driver IKN dan Ekspansi
Pertambangan**

Mata Kuliah: Seminar / Tugas Akhir

Dosen Pengampu: Robert Kurniawan, S.S.T., M.Si.

Jakarta, Mei 2025

RINGKASAN

Pulau Kalimantan menjadi salah satu kawasan dengan tekanan spasial terbesar di Indonesia akibat konvergensi dua driver perubahan tutupan lahan yang bersifat masif dan simultan: pembangunan Ibu Kota Nusantara (IKN) di Kalimantan Timur serta ekspansi aktivitas pertambangan dan gangguan lahan terbuka (bare land disturbance) yang terus meluas di berbagai provinsi. Meskipun terdapat polemik politik mengenai kepastian perpindahan aparat sipil negara, pembangunan fisik infrastruktur IKN tetap berlangsung secara intensif, yang berarti transformasi spasial di kawasan tersebut telah dan terus terjadi secara nyata. Di sisi lain, ekspansi pertambangan batubara dan nikel di Kalimantan Tengah, Selatan, dan Timur menambah tekanan terhadap hutan tropis yang tersisa.

Penelitian ini mengusulkan pendekatan klasifikasi tutupan lahan berbasis supervised machine learning dengan menggunakan citra Sentinel-2 SR Harmonized yang diakses melalui platform Google Earth Engine (GEE) untuk periode 2018 hingga 2024. Framework metodologi yang digunakan adalah CRISP-DM. Sebanyak enam algoritma machine learning dibandingkan, yaitu Random Forest, XGBoost, LightGBM, Logistic Regression, Support Vector Machine (SVM), dan Multilayer Perceptron (MLP). Label kelas tutupan lahan bersumber dari ESA WorldCover 2021 yang diperkaya dengan interpretasi visual. Fitur yang digunakan meliputi band spektral Sentinel-2 (B2, B3, B4, B8, B11, B12) serta indeks turunan NDVI, NDBI, NDMI, dan BSI, ditambah fitur topografi dari SRTM dan faktor iklim dari CHIRPS.

Evaluasi model dilakukan menggunakan Spatial Block Cross Validation untuk menghindari spatial autocorrelation leakage, dengan metrik Overall Accuracy, F1 Macro, Cohen Kappa, IoU per kelas, Producer's Accuracy, dan User's Accuracy. Deteksi perubahan tutupan lahan dilakukan melalui post-classification comparison dan transition matrix untuk memvisualisasikan arah perubahan antar kelas pada periode 2018, 2020, 2022, dan 2024. Interpretabilitas model dianalisis menggunakan SHAP (SHapley Additive exPlanations) untuk memahami kontribusi masing-masing fitur spektral dan lingkungan terhadap prediksi kelas tutupan lahan. Hasil penelitian disajikan dalam bentuk dashboard/web GIS interaktif yang dilengkapi temporal slider, change detection map, hotspot analysis, dan SHAP visualization.

I. PENDAHULUAN

1.1 Latar Belakang

Kalimantan merupakan pulau terbesar ketiga di dunia dan rumah bagi salah satu kawasan hutan tropis dengan keanekaragaman hayati paling tinggi di planet ini. Sebagian besar wilayahnya masuk ke dalam ekosistem hutan hujan tropis dataran rendah yang memiliki fungsi ekologis kritis: sebagai penyimpan karbon dalam skala global, sebagai habitat bagi spesies endemik seperti orangutan Borneo (*Pongo pygmaeus*) dan bekantan (*Nasalis larvatus*), serta sebagai pengatur siklus hidrologi regional. Namun, dalam dua dekade terakhir, Kalimantan telah mengalami laju deforestasi yang sangat mengkhawatirkan akibat ekspansi perkebunan kelapa sawit, eksploitasi tambang, dan pembukaan lahan untuk keperluan infrastruktur. Menurut analisis Hansen et al. yang dipublikasikan melalui platform Global Forest Watch, Kalimantan telah kehilangan lebih dari 20% tutupan pohon aslinya dalam periode 2000–2020, dengan laju kerugian yang semakin meningkat seiring meningkatnya permintaan komoditas dan aksesibilitas infrastruktur.

Tekanan terhadap tutupan lahan Kalimantan semakin kompleks dengan hadirnya dua fenomena besar yang bersifat simultan. Pertama adalah proyek pembangunan Ibu Kota Nusantara (IKN) di Kalimantan Timur yang secara resmi dimulai konstruksinya sejak tahun 2022 berdasarkan Undang-Undang Nomor 3 Tahun 2022. IKN mencakup kawasan inti pemerintahan pusat seluas 5.619 km² dan kawasan pengembangan seluas 35.692 km² yang meliputi sebagian wilayah Kabupaten Penajam Paser Utara dan Kabupaten Kutai Kartanegara. Meskipun terdapat dinamika kebijakan dan polemik publik mengenai kemungkinan pusat pemerintahan tetap dipertahankan di Jakarta—yang diperkuat oleh berbagai pernyataan pejabat pemerintah pada tahun 2024 dan 2025—fakta lapangan menunjukkan bahwa pembangunan fisik infrastruktur di kawasan IKN, mencakup jalan tol, gedung pemerintahan, kawasan permukiman, dan fasilitas pendukung, terus berlangsung. Hal ini berarti bahwa konversi tutupan lahan dari hutan tropis dan lahan pertanian menjadi kawasan terbangun telah dan akan terus terjadi terlepas dari kepastian status perpindahan aparatur sipil negara (ASN). Transformasi spasial yang dipicu oleh IKN dengan demikian merupakan fenomena yang harus dipantau secara ilmiah dan empiris, bukan spekulatif.

Kedua adalah ekspansi aktivitas pertambangan yang semakin meluas di seluruh Kalimantan. Kalimantan Timur, Kalimantan Selatan, dan Kalimantan Tengah merupakan

provinsi dengan konsesi pertambangan batubara terbesar di Indonesia. Sementara itu, pertambangan nikel sedang berkembang pesat di berbagai kabupaten, didorong oleh meningkatnya permintaan global untuk bahan baku baterai kendaraan listrik. Aktivitas pertambangan menciptakan dampak spasial yang khas: pembukaan lahan vegetasi dalam skala besar, penggalian yang meninggalkan lahan terbuka (*bare land*) dan kolam penampungan, serta pembangunan infrastruktur akses seperti jalan hauling dan pelabuhan yang memotong kawasan hutan. Karakteristik spektral lahan tambang, yang didominasi oleh tanah terbuka dan batuan, dapat dibedakan dari kelas tutupan lahan lainnya melalui analisis citra multispektral. Meskipun demikian, penting untuk dicatat bahwa identifikasi pertambangan dalam penelitian ini dilakukan melalui pendekatan proxy berbasis deteksi *bare land* dan perubahan spektral, bukan melalui konfirmasi lapangan langsung, sehingga interpretasi harus dilakukan dengan kehati-hatian ilmiah.

Konvergensi dua driver perubahan tutupan lahan ini—IKN dan pertambangan—menciptakan apa yang dapat disebut sebagai *double pressure* terhadap ekosistem Kalimantan. Kedua fenomena tersebut beroperasi pada skala spasial yang berbeda namun saling berinteraksi: IKN bersifat terkonsentrasi pada satu zona geografis tertentu namun berdampak sangat intensif, sementara pertambangan bersifat tersebar dan terus berekspansi secara temporal. Memahami dinamika perubahan tutupan lahan yang dipicu oleh kedua driver ini secara simultan merupakan kontribusi penting bagi ilmu pengetahuan dan kebijakan berbasis bukti (*evidence-based policy*).

Pemantauan perubahan tutupan lahan secara konvensional melalui survei lapangan (*field survey*) memiliki keterbatasan fundamental dalam konteks ini. Cakupan spasial survei lapangan sangat terbatas mengingat luas Kalimantan yang mencapai lebih dari 743.000 km², sementara biaya dan waktu yang diperlukan sangat besar. Di sisi lain, data administrasi pertanahan dan izin usaha pertambangan (IUP) seringkali tidak mencerminkan kondisi aktual di lapangan akibat kelemahan dalam pengawasan dan penegakan hukum. Pendekatan penginderaan jauh (*remote sensing*) berbasis citra satelit menawarkan solusi yang superior dalam konteks ini: cakupan spasial yang luas, kemampuan pemantauan multitemporal secara konsisten, biaya akuisisi data yang semakin terjangkau, dan kemampuan untuk mengekstraksi informasi tentang permukaan bumi secara kuantitatif dari nilai reflektansi spektral.

Satelit Sentinel-2 dari program Copernicus milik European Space Agency (ESA) merupakan salah satu platform penginderaan jauh paling relevan untuk pemetaan tutupan lahan di wilayah tropis. Dengan resolusi spasial 10 meter untuk band visible dan NIR, resolusi 20 meter untuk band SWIR, serta revisit time 5 hari untuk satu satelit (2–3 hari dengan dua satelit kembar), Sentinel-2 menyediakan data yang sangat kaya untuk analisis multitemporal. Tersedianya produk Surface Reflectance (SR) Harmonized yang telah terkoreksi atmosfer melalui algoritma FORCE/Sen2Cor memastikan konsistensi radiometrik antar waktu yang dibutuhkan untuk analisis temporal yang valid. Seluruh arsip Sentinel-2 sejak 2015 dapat diakses secara gratis melalui platform Google Earth Engine (GEE), yang menyediakan kapabilitas komputasi awan (cloud computing) untuk memproses data citra bervolume besar tanpa perlu infrastruktur komputasi lokal.

Dalam konteks machine learning untuk land cover classification, perkembangan algoritma ensemble dan boosting telah menghasilkan peningkatan akurasi yang signifikan dibandingkan pendekatan klasifikasi konvensional seperti maximum likelihood. Random Forest, yang merupakan ensemble dari decision trees, telah terbukti sangat efektif untuk klasifikasi tutupan lahan karena kemampuannya menangani fitur yang saling berkorelasi, robustness terhadap outlier, dan kemampuan menghasilkan feature importance. Algoritma gradient boosting seperti XGBoost dan LightGBM menawarkan kecepatan komputasi yang lebih tinggi dengan akurasi yang kompetitif. Integrasi multiple algoritma dalam satu framework komparatif memungkinkan peneliti untuk mengidentifikasi metode yang paling optimal untuk karakteristik data tertentu.

Namun demikian, klasifikasi tutupan lahan berbasis citra satelit menghadapi tantangan metodologis yang serius dalam hal evaluasi model: spatial autocorrelation. Data citra satelit memiliki ketergantungan spasial (spatial dependency) yang inheren—piksel yang berdekatan cenderung memiliki nilai yang mirip karena berasal dari objek atau kondisi yang sama secara fisik. Jika sampel training dan testing dipilih secara acak tanpa mempertimbangkan struktur spasial ini, model cenderung menghasilkan estimasi akurasi yang inflated (terlalu optimistis) karena sampel test secara tidak langsung sudah 'bocor' informasinya ke dalam training set. Spatial Block Cross Validation (SBCV) merupakan pendekatan yang semakin banyak diadopsi dalam komunitas geospatial machine learning untuk mengatasi masalah ini dengan memastikan bahwa blok spasial yang digunakan sebagai validation set secara geografis terpisah dari blok training.

Di luar akurasi, interpretabilitas model machine learning juga merupakan aspek penting yang sering diabaikan dalam penelitian tutupan lahan. Memahami fitur mana yang paling berkontribusi terhadap prediksi kelas tertentu memiliki nilai ilmiah dan praktis: secara ilmiah, ini memvalidasi apakah model belajar dari hubungan yang masuk akal secara spektral dan ekologis; secara praktis, ini membantu dalam optimasi fitur untuk penelitian selanjutnya. SHAP (SHapley Additive exPlanations) yang dikembangkan oleh Lundberg dan Lee (2017) menyediakan framework yang kuat untuk interpretabilitas model dengan landasan teoretis yang solid dari teori permainan kooperatif (cooperative game theory).

Berdasarkan uraian di atas, terdapat kesenjangan (gap) penelitian yang signifikan: belum ada penelitian yang secara sistematis menganalisis transformasi tutupan lahan Kalimantan secara multitemporal dengan mempertimbangkan secara simultan dua driver utama (IKN dan pertambangan), menggunakan framework machine learning yang komprehensif dengan evaluasi metodologis yang ketat (SBCV), serta dilengkapi dengan analisis interpretabilitas model (SHAP) dan visualisasi hasil melalui dashboard spasial interaktif. Penelitian ini hadir untuk mengisi gap tersebut dengan kontribusi yang bersifat metodologis, empiris, dan praktis.

1.2 Identifikasi Masalah

Berdasarkan latar belakang yang telah diuraikan, terdapat beberapa permasalahan yang teridentifikasi dalam penelitian ini:

1. Belum tersedianya peta tutupan lahan multitemporal Kalimantan yang secara komprehensif mencakup periode 2018–2024 dengan resolusi spasial memadai berbasis Sentinel-2.
2. Belum adanya kajian komparatif performa algoritma machine learning (Random Forest, XGBoost, LightGBM, Logistic Regression, SVM, dan MLP) untuk klasifikasi tutupan lahan Kalimantan dengan evaluasi berbasis Spatial Block Cross Validation.
3. Belum ada penelitian yang menganalisis secara simultan pengaruh dual-driver IKN dan ekspansi pertambangan terhadap transformasi spasial tutupan lahan Kalimantan dalam satu kerangka analisis terpadu.

4. Terbatasnya penerapan analisis interpretabilitas model berbasis SHAP dalam konteks klasifikasi tutupan lahan tropis menggunakan data Sentinel-2 multitemporal.
5. Belum tersedianya platform visualisasi spasial interaktif yang mengintegrasikan hasil klasifikasi multitemporal, deteksi perubahan, dan analisis hotspot tutupan lahan Kalimantan secara terpadu.

1.3 Rumusan Masalah

Berdasarkan identifikasi masalah yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana performa komparatif algoritma Random Forest, XGBoost, LightGBM, Logistic Regression, SVM, dan MLP dalam mengklasifikasikan tutupan lahan Kalimantan berbasis fitur spektral Sentinel-2 dan indeks turunannya, diukur dengan Spatial Block Cross Validation?
2. Bagaimana pola transformasi tutupan lahan Kalimantan selama periode 2018–2024, dan ke arah mana transisi antar kelas tutupan lahan yang paling dominan terjadi?
3. Bagaimana karakteristik spasio-temporal perubahan tutupan lahan di sekitar kawasan IKN dibandingkan dengan kawasan pertambangan, dan apakah terdapat perbedaan yang dapat diidentifikasi dalam pola perubahan yang dihasilkan oleh kedua driver tersebut?
4. Fitur spektral dan lingkungan mana yang memiliki kontribusi terbesar terhadap klasifikasi kelas tutupan lahan tertentu berdasarkan analisis SHAP?
5. Bagaimana mengintegrasikan hasil analisis ke dalam platform dashboard/web GIS interaktif yang dapat digunakan sebagai alat pemantauan tutupan lahan berbasis bukti?

1.4 Tujuan Penelitian

Tujuan penelitian ini adalah sebagai berikut:

1. Mengembangkan model klasifikasi tutupan lahan Kalimantan berbasis fitur spektral Sentinel-2 SR Harmonized dan indeks turunannya menggunakan enam algoritma supervised machine learning.
2. Membandingkan performa algoritma Random Forest, XGBoost, LightGBM, Logistic Regression, SVM, dan MLP menggunakan Spatial Block Cross Validation untuk mengidentifikasi model terbaik.
3. Mendeteksi dan memetakan perubahan tutupan lahan Kalimantan selama periode 2018–2024 melalui post-classification comparison dan analisis transition matrix.
4. Menganalisis karakteristik spasio-temporal perubahan tutupan lahan yang berkaitan dengan dual-driver IKN dan ekspansi pertambangan/bare land.
5. Mengidentifikasi kontribusi fitur spektral dan lingkungan terhadap prediksi kelas tutupan lahan menggunakan analisis SHAP.
6. Mengembangkan dashboard/web GIS interaktif untuk visualisasi hasil penelitian yang dapat digunakan sebagai alat pemantauan spasial berbasis web.

1.5 Manfaat Penelitian

1.5.1 Manfaat Akademis

Secara akademis, penelitian ini diharapkan memberikan kontribusi metodologis dalam pengembangan kerangka analisis machine learning untuk klasifikasi tutupan lahan tropis yang mempertimbangkan aspek spatial autocorrelation melalui Spatial Block Cross Validation. Selain itu, penelitian ini berkontribusi pada pemahaman tentang penerapan SHAP interpretability dalam konteks geospatial machine learning, yang masih relatif jarang didokumentasikan dalam literatur berbahasa Indonesia. Integrasi dual-driver analysis dalam satu framework penelitian juga merupakan kontribusi konseptual yang dapat menjadi referensi bagi penelitian-penelitian berikutnya.

1.5.2 Manfaat Praktis

Secara praktis, peta perubahan tutupan lahan yang dihasilkan dapat menjadi referensi bagi pemerintah daerah, kementerian terkait (KLHK, ATR/BPN, ESDM), serta lembaga riset dalam perencanaan tata ruang berbasis bukti. Identifikasi hotspot deforestasi dan ekspansi lahan terbuka yang berkorelasi dengan aktivitas pertambangan dapat

mendukung upaya pengawasan dan penegakan hukum di sektor tersebut. Dashboard spasial interaktif yang dihasilkan dapat dimanfaatkan sebagai alat komunikasi data yang efektif kepada berbagai pemangku kepentingan, termasuk masyarakat umum, organisasi lingkungan hidup, dan peneliti.

II. TINJAUAN PUSTAKA

2.1 Konsep Tutupan Lahan dan Perubahannya

Tutupan lahan (land cover) didefinisikan sebagai kondisi fisik permukaan bumi yang terobservasi, mencakup berbagai kategori seperti hutan, lahan pertanian, badan air, lahan terbangun, dan lahan terbuka. Berbeda dengan penggunaan lahan (land use) yang merujuk pada tujuan sosio-ekonomis pemanfaatan lahan, tutupan lahan merupakan deskripsi biofisik yang dapat diukur secara langsung melalui penginderaan jauh. Perubahan tutupan lahan (land cover change) merupakan transformasi dari satu kategori ke kategori lain dalam rentang waktu tertentu, yang dapat disebabkan oleh faktor alami (seperti kebakaran hutan, banjir, atau suksesi vegetasi) maupun faktor antropogenik (seperti deforestasi, urbanisasi, atau konversi pertanian).

Pemantauan perubahan tutupan lahan secara multitemporal memiliki urgensi yang tinggi dalam konteks kebijakan lingkungan global. Konvensi Kerangka Kerja PBB tentang Perubahan Iklim (UNFCCC) mewajibkan negara-negara anggota untuk melaporkan perubahan tutupan lahan sebagai bagian dari inventarisasi gas rumah kaca, mengingat sektor kehutanan dan penggunaan lahan merupakan sumber emisi karbon yang signifikan. Di tingkat nasional, Indonesia memiliki komitmen untuk menurunkan emisi gas rumah kaca sebesar 41% dengan dukungan internasional pada tahun 2030 (NDC Indonesia), yang sebagian besar bergantung pada keberhasilan pengelolaan tutupan lahan hutan. Dalam konteks ini, pemantauan tutupan lahan yang akurat dan berkala menjadi kebutuhan fundamental.

2.2 Penginderaan Jauh untuk Pemetaan Tutupan Lahan

Penginderaan jauh (remote sensing) merupakan ilmu dan teknologi untuk memperoleh informasi tentang objek, area, atau fenomena dari jarak jauh tanpa kontak fisik langsung, umumnya menggunakan sensor berbasis satelit atau pesawat yang merekam energi elektromagnetik yang dipantulkan atau dipancarkan oleh permukaan bumi. Dalam konteks pemetaan tutupan lahan, prinsip dasar yang dimanfaatkan adalah perbedaan karakteristik reflektansi spektral (spectral signature) antara berbagai jenis tutupan lahan. Vegetasi sehat, misalnya, memiliki absorpsi tinggi pada panjang gelombang merah (red) karena klorofil, dan reflektansi sangat tinggi pada near-infrared (NIR) akibat struktur sel

mesofil daun. Lahan terbangun cenderung memiliki reflektansi tinggi di seluruh spektrum visible, sementara badan air memiliki absorpsi tinggi di NIR dan SWIR.

Citra multispektral yang merekam reflektansi di beberapa band spektral secara simultan memungkinkan diskriminasi antar kelas tutupan lahan berdasarkan perbedaan signature spektral ini. Akurasi diskriminasi dapat ditingkatkan dengan menggunakan indeks spektral turunan yang mengoptimalkan kontras antara kelas-kelas tertentu. NDVI (Normalized Difference Vegetation Index), yang dihitung dari rasio band NIR dan Red, merupakan indeks paling banyak digunakan untuk memantau vegetasi. NDBI (Normalized Difference Built-up Index) menggunakan band SWIR dan NIR untuk mendeteksi kawasan terbangun. NDMI (Normalized Difference Moisture Index) sensitif terhadap kandungan air vegetasi menggunakan NIR dan SWIR1. BSI (Bare Soil Index) mengkombinasikan band SWIR2, Red, NIR, dan Blue untuk mendeteksi lahan terbuka tanpa vegetasi.

2.3 Sentinel-2 dan Google Earth Engine

Program Copernicus milik European Space Agency (ESA) meluncurkan pasangan satelit Sentinel-2A (2015) dan Sentinel-2B (2017) yang membentuk satu konstelasi penginderaan jauh multi-spektral untuk pemantauan daratan. Sensor Multispectral Instrument (MSI) pada Sentinel-2 merekam data pada 13 band spektral dengan resolusi spasial yang bervariasi: 10 meter untuk band visible dan NIR (B2, B3, B4, B8), 20 meter untuk band red-edge dan SWIR (B5, B6, B7, B8A, B11, B12), dan 60 meter untuk band koreksi atmosfer (B1, B9, B10). Revisit time konstelasi Sentinel-2 adalah 5 hari di ekuator, yang merupakan frekuensi pemerolehan data yang memadai untuk analisis multitemporal dengan cakupan temporal yang baik meskipun terdapat tutupan awan.

Produk Sentinel-2 Level-2A (Surface Reflectance/SR) telah terkoreksi dari efek atmosfer menggunakan algoritma Sen2Cor, menghasilkan nilai reflektansi permukaan (Bottom-of-Atmosphere/BOA) yang lebih stabil secara temporal dibandingkan reflektansi puncak atmosfer (Top-of-Atmosphere/TOA). Koleksi Sentinel-2 SR Harmonized di Google Earth Engine (GEE) telah menerapkan harmonisasi tambahan untuk meminimalkan perbedaan antara sensor Sentinel-2A dan 2B, sehingga menghasilkan time series yang lebih konsisten untuk analisis perubahan. Ini sangat penting untuk analisis tutupan lahan multitemporal yang memerlukan konsistensi radiometrik antar akuisisi.

Google Earth Engine (GEE) merupakan platform komputasi geospasial berbasis cloud yang dikembangkan oleh Google, menyediakan akses terhadap petabyte data citra satelit historis dan kemampuan komputasi masif untuk analisis spasial. GEE memungkinkan pengguna untuk menulis skrip JavaScript atau Python (melalui Earth Engine Python API) untuk mengakses, memproses, dan menganalisis data citra satelit dalam skala global tanpa perlu mengunduh data ke komputer lokal. Kemampuan ini sangat krusial untuk penelitian ini yang memerlukan pemrosesan koleksi citra Sentinel-2 selama enam tahun (2018–2024) di seluruh Pulau Kalimantan, yang secara praktis tidak memungkinkan dilakukan dengan komputasi lokal mengingat volume data yang besar.

2.4 ESA WorldCover sebagai Referensi Klasifikasi

ESA WorldCover merupakan peta tutupan lahan global dengan resolusi 10 meter yang dihasilkan oleh European Space Agency menggunakan data Sentinel-1 dan Sentinel-2. Versi pertama (2020) dan versi kedua (2021) dari ESA WorldCover menyediakan klasifikasi ke dalam 11 kelas tutupan lahan yang mencakup: Tree Cover, Shrubland, Grassland, Cropland, Built-up, Bare/Sparse Vegetation, Snow and Ice, Permanent Water Bodies, Herbaceous Wetland, Mangroves, dan Moss and Lichen. Akurasi overall dari peta ini secara global telah divalidasi mencapai lebih dari 74%, dengan akurasi yang lebih tinggi untuk kelas-kelas utama seperti Tree Cover, Built-up, dan Water Bodies.

Dalam penelitian ini, ESA WorldCover 2021 dimanfaatkan sebagai sumber label training utama (reference data) untuk melatih model machine learning. Pendekatan ini termasuk dalam kategori weakly supervised learning atau label transfer yang telah banyak diterapkan dalam penelitian klasifikasi tutupan lahan global. Meskipun ESA WorldCover memiliki keterbatasan dalam hal akurasi untuk kelas-kelas tertentu di konteks lokal Indonesia—khususnya untuk membedakan perkebunan dari hutan sekunder dan untuk mengidentifikasi tambang—penggunaannya sebagai baseline yang diperkaya dengan interpretasi visual lokal merupakan pendekatan yang pragmatis dan dapat dipertanggungjawabkan secara metodologis.

2.5 Algoritma Machine Learning untuk Klasifikasi Tutupan Lahan

2.5.1 Random Forest

Random Forest (RF) merupakan metode ensemble yang mengombinasikan sejumlah besar decision trees yang dilatih secara independen menggunakan subset acak

dari data training (bootstrap sampling) dan subset acak dari fitur pada setiap split (feature bagging). Prediksi akhir RF merupakan majority vote dari prediksi seluruh pohon untuk masalah klasifikasi. Breiman (2001), yang mengembangkan algoritma ini, menunjukkan bahwa dengan meningkatkan keragaman antar pohon melalui randomisasi, varians kesalahan prediksi secara agregat dapat dikurangi secara signifikan tanpa meningkatkan bias. Random Forest dikenal sangat robust terhadap overfitting, efektif menangani fitur yang saling berkorelasi tinggi—kondisi yang sangat umum dalam data citra multispektral—serta menghasilkan feature importance yang informatif.

2.5.2 XGBoost dan LightGBM

XGBoost (eXtreme Gradient Boosting) yang dikembangkan oleh Chen dan Guestrin (2016) merupakan implementasi gradient boosting yang dioptimalkan untuk kecepatan dan akurasi. Berbeda dengan Random Forest yang melatih pohon secara paralel dan independen, XGBoost melatih pohon secara sekuensial di mana setiap pohon baru berfokus untuk mengoreksi kesalahan pohon sebelumnya. XGBoost menambahkan regularisasi L1 dan L2 ke dalam fungsi objektif untuk mencegah overfitting, serta menggunakan pendekatan tree pruning yang lebih agresif. LightGBM (Light Gradient Boosting Machine) yang dikembangkan oleh Microsoft merupakan evolusi dari gradient boosting yang menggunakan dua teknik utama: Gradient-based One-Side Sampling (GOSS) untuk mereduksi jumlah sampel data tanpa kehilangan informasi penting, dan Exclusive Feature Bundling (EFB) untuk mereduksi dimensi fitur yang mutually exclusive. Hasilnya, LightGBM umumnya jauh lebih cepat daripada XGBoost dengan akurasi yang sebanding.

2.5.3 Logistic Regression, SVM, dan MLP

Logistic Regression (LR) merupakan model linier yang memodelkan probabilitas keanggotaan kelas menggunakan fungsi sigmoid (logistic). Meskipun asumsi linearitasnya membatasi kemampuannya dalam menangkap pola non-linier yang kompleks, LR berfungsi sebagai baseline yang kuat dan interpretatif. Support Vector Machine (SVM) bekerja dengan mencari hyperplane yang memaksimalkan margin antara kelas-kelas berbeda di ruang fitur. Kernel trick—menggunakan kernel function seperti RBF—memungkinkan SVM untuk mempelajari batas keputusan non-linier yang kompleks di ruang dimensi tinggi. SVM telah terbukti efektif untuk klasifikasi citra satelit terutama ketika dimensi fitur relatif tinggi dibandingkan jumlah sampel. Multilayer Perceptron

(MLP) merupakan jaringan saraf tiruan yang terdiri dari beberapa lapisan fully-connected neurons dengan fungsi aktivasi non-linier (seperti ReLU), mampu memodelkan fungsi yang sangat kompleks melalui proses backpropagation. Dalam konteks penelitian ini, MLP digunakan dengan arsitektur yang terbatas (bukan deep learning) agar komputasi tetap feasible.

2.6 Spatial Block Cross Validation

Cross validation konvensional (k-fold random CV) mengasumsikan bahwa setiap observasi bersifat independently and identically distributed (i.i.d.). Asumsi ini dilanggar secara fundamental oleh data spasial karena hukum pertama geografi Tobler: 'segala sesuatu berkaitan dengan yang lain, tetapi hal-hal yang berdekatan lebih berkaitan daripada yang jauh.' Dalam klasifikasi tutupan lahan berbasis citra satelit, piksel atau sampel yang berdekatan secara geografis cenderung memiliki kemiripan spektral yang tinggi, baik karena berasal dari objek fisik yang sama maupun karena efek point spread function dan resampling. Akibatnya, jika sampel training dan testing dibagi secara acak, banyak sampel test akan sangat mirip dengan sampel training terdekatnya, menghasilkan estimasi akurasi yang inflated.

Spatial Block Cross Validation (Roberts et al., 2017; Valavi et al., 2019) mengatasi masalah ini dengan membagi data ke dalam blok spasial yang saling tidak tumpang tindih, di mana seluruh blok digunakan secara bergantian sebagai validation set. Ukuran blok dipilih berdasarkan jangkauan autokorelasi spasial dari data, yang dapat diestimasi menggunakan analisis variogram atau Moran's I. Pendekatan ini memastikan bahwa sampel training dan testing secara geografis terpisah, sehingga evaluasi akurasi yang dihasilkan lebih mencerminkan kemampuan generalisasi model ke area baru yang belum pernah dilihat selama training.

2.7 SHAP Interpretability

SHAP (SHapley Additive exPlanations) adalah metode interpretabilitas model machine learning yang dikembangkan oleh Lundberg dan Lee (2017) berdasarkan konsep Shapley values dari teori permainan kooperatif. Untuk setiap prediksi individual, SHAP menghitung kontribusi masing-masing fitur terhadap penyimpangan prediksi tersebut dari baseline (rata-rata prediksi). Secara formal, SHAP value untuk fitur i pada prediksi untuk sampel x adalah rata-rata tertimbang dari kontribusi marginal fitur i di semua permutasi

kemungkinan koalisi fitur lainnya. Properti unik SHAP adalah konsistensi dan lokalitas: secara global konsisten (fitur yang lebih 'penting' selalu mendapat nilai lebih tinggi) dan secara lokal akurat (jumlah SHAP values sama dengan deviasi prediksi dari baseline).

Dalam konteks klasifikasi tutupan lahan, SHAP memberikan wawasan tentang fitur spektral mana yang paling berkontribusi terhadap klasifikasi kelas tertentu. Misalnya, apakah NDVI merupakan fitur paling dominan untuk kelas hutan dibandingkan indeks lainnya? Apakah NDBI memiliki kontribusi positif yang signifikan untuk kelas lahan terbangun? Informasi ini memvalidasi bahwa model belajar dari hubungan yang masuk akal secara spektral dan ekologis, bukan dari artefak data atau kebetulan statistik.

2.8 Change Detection Multitemporal

Deteksi perubahan (change detection) dalam konteks penginderaan jauh merujuk pada proses identifikasi perbedaan kondisi tutupan lahan antara dua atau lebih titik waktu berbeda. Berbagai metode change detection telah dikembangkan dalam literatur remote sensing, yang dapat dikategorikan ke dalam image differencing, post-classification comparison, dan object-based approaches. Metode post-classification comparison (PCC) yang digunakan dalam penelitian ini bekerja dengan mengklasifikasikan citra pada setiap titik waktu secara independen, kemudian membandingkan peta klasifikasi yang dihasilkan piksel per piksel untuk mengidentifikasi perubahan. Keunggulan PCC adalah kemampuannya menghasilkan informasi arah perubahan ('dari kelas A menjadi kelas B') yang tersaji dalam transition matrix.

Matriks transisi (transition matrix) merupakan representasi matematis dari perubahan tutupan lahan yang menunjukkan luas area yang berpindah dari setiap kelas tutupan lahan pada waktu t_1 ke setiap kelas pada waktu t_2 . Matriks ini memungkinkan kuantifikasi dari perubahan spesifik, misalnya berapa luas hutan yang berubah menjadi lahan terbangun, atau berapa luas lahan terbuka yang berubah menjadi vegetasi tumbuh kembali. Visualisasi Sankey diagram merupakan salah satu pendekatan yang efektif untuk menyajikan informasi transition matrix kepada audiens non-teknis.

2.9 Pembangunan IKN dan Deforestasi Kalimantan

Proyek Ibu Kota Nusantara (IKN) merupakan salah satu proyek infrastruktur terbesar dalam sejarah Indonesia. Berdasarkan Undang-Undang No. 3 Tahun 2022 dan perubahannya UU No. 21 Tahun 2023, IKN berlokasi di Kalimantan Timur dengan total

luas wilayah Ibu Kota Nusantara mencapai 256.142 hektar, yang terbagi menjadi Kawasan Inti Pusat Pemerintahan (KIPP) seluas 5.619 hektar dan kawasan pengembangan IKN. Pembangunan fisik dimulai pada 2022 dan mencakup infrastruktur dasar seperti jalan tol IKN, Istana Garuda, gedung-gedung pemerintahan, dan kawasan permukiman Nusantara. Meskipun terdapat diskursus publik mengenai kemungkinan pusat pemerintahan tetap dipertahankan di Jakarta, fakta lapangan menunjukkan bahwa konversi tutupan lahan di kawasan IKN telah terjadi secara masif dan terus berlangsung.

Kalimantan secara historis mengalami deforestasi yang intens. Studi Hansen et al. (2013) dan update-nya melalui Global Forest Watch mencatat bahwa Indonesia adalah salah satu negara dengan laju deforestasi tropika tertinggi di dunia. Kalimantan khususnya mengalami kehilangan tutupan pohon yang signifikan akibat konversi ke perkebunan kelapa sawit, pembangunan infrastruktur, dan eksploitasi tambang. Hutan gambut Kalimantan yang memiliki cadangan karbon tinggi sangat rentan terhadap degradasi dan kebakaran, sebagaimana dibuktikan oleh bencana kebakaran hutan dan lahan berulang yang dikaitkan dengan El Niño dan praktik pembukaan lahan.

2.10 Ekspansi Pertambangan di Kalimantan

Kalimantan merupakan episentrum industri pertambangan batubara Indonesia. Provinsi Kalimantan Timur, Kalimantan Selatan, dan Kalimantan Tengah memiliki cadangan batubara terbesar di negeri ini, dengan puluhan perusahaan pertambangan beroperasi di wilayah tersebut. Selain batubara, ekspansi pertambangan nikel di Kalimantan Timur dan Kalimantan Tengah semakin meningkat dalam beberapa tahun terakhir, didorong oleh permintaan global untuk bahan baku baterai kendaraan listrik. Aktivitas pertambangan menciptakan signature spektral yang khas pada citra satelit: tanah terbuka, kolam sedimentasi (settling pond), stockpile batubara, dan infrastruktur transportasi yang dapat diidentifikasi dari nilai NDVI rendah, BSI tinggi, dan perubahan temporal yang abrupt.

Penting untuk dicatat bahwa penelitian ini mengidentifikasi ekspansi pertambangan secara tidak langsung melalui deteksi bare land disturbance—yaitu peningkatan luas lahan terbuka yang tidak tervegetasi pada lokasi yang berkorelasi spasial dengan kawasan konsesi pertambangan. Pendekatan ini merupakan proxy yang valid namun harus diinterpretasikan dengan hati-hati karena lahan terbuka juga dapat berasal dari aktivitas lain seperti pembukaan lahan pertanian, pembangunan infrastruktur non-tambang, atau kebakaran

hutan. Klaim tentang aktivitas pertambangan dalam penelitian ini bersifat indikatif dan berbasis analisis spasial, bukan konfirmasi lapangan.

2.11 Penelitian Terdahulu

Berikut disajikan ringkasan penelitian-penelitian terdahulu yang relevan dengan topik penelitian ini:

Peneliti (Tahun)	Tujuan Penelitian	Metode	Dataset & Lokasi	Algoritma Terbaik	Relevansi dengan Penelitian Ini
Phiri et al. (2021) Remote Sensing	Evaluasi komparatif Sentinel-2 untuk land cover classification di Afrika Selatan menggunakan berbagai ML classifier	Random Forest, SVM, Logistic Regression; 10-fold CV; fitur spektral + indeks	Sentinel-2 SR; Afrika Selatan; 8 kelas tutupan lahan	Random Forest (OA 91.3%)	Acuan metodologi komparasi multi-algoritma dan pemilihan fitur spektral Sentinel-2 untuk klasifikasi tutupan lahan
Pelletier et al. (2019) ISPRS JPRS	Membandingkan RF, SVM, dan 1D-CNN untuk klasifikasi time-series land cover menggunakan fitur temporal Sentinel-2	RF, SVM, 1D-CNN; SITS (satellite image time series); fitur temporal agregat per musim	Sentinel-2 multi-temporal; Perancis Selatan; 9 kelas	RF dan CNN setara, SVM sedikit lebih rendah	Justifikasi penggunaan fitur spektral temporal agregat dan perbandingan performa algoritma ensemble vs linier
Valavi et al. (2019) Methods in Ecology & Evolution	Mengusulkan dan mengevaluasi Spatial Block CV untuk mengurangi spatial autocorrelation leakage dalam	Spatial Block CV, Buffered LOO CV; dibandingkan dengan random CV; metrics: AUC, RMSE	Data simulasi dan empiris; berbagai lokasi; habitat modeling	Spatial Block CV mengurangi optimisme estimasi akurasi secara signifikan	Landasan metodologis utama untuk penerapan SBCV dalam penelitian ini sebagai

Peneliti (Tahun)	Tujuan Penelitian	Metode	Dataset & Lokasi	Algoritma Terbaik	Relevansi dengan Penelitian Ini
	SDM dan land mapping		dan land classification		alternatif random CV
Lundberg et al. (2020) Nature Machine Intelligence	Mengembangkan TreeSHAP untuk komputasi SHAP values yang efisien pada tree-based models	SHAP (Shapley Additive exPlanations); TreeSHAP algorithm; interpretasi global dan lokal	Berbagai dataset ML; kasus klasifikasi dan regresi	TreeSHAP exact untuk RF/XGBoost/LightGBM	Dasar teoretis dan implementasi SHAP untuk interpretasi model klasifikasi tutupan lahan dalam penelitian ini
Descals et al. (2021) Global Change Biology	Pemetaan deforestasi dan konversi hutan ke perkebunan sawit di Kalimantan dan Sumatra menggunakan Landsat time-series	Annual change detection; CCDC (Continuous Change Detection and Classification); annual land cover maps 2001-2019	Landsat 5/7/8; Kalimantan dan Sumatra; kelas hutan, sawit, non-hutan	CCDC-based approach, akurasi > 85%	Referensi konteks deforestasi Kalimantan dan metodologi change detection multitemporal; penelitian ini memperluas ke Sentinel-2 dan dual-driver
Dong et al. (2023) Remote Sensing of Environment	Pemetaan global annual land cover 2000-2022 menggunakan Landsat dan Sentinel-2 time-series	Multi-sensor compositing; RF classifier; transition-based annual update; 10m resolution (2017+)	Landsat + Sentinel-2 SR; Global; 10 kelas (LCSM v1.0)	RF, OA ~82% global	Referensi metodologi pembuatan peta tutupan lahan multi-temporal dengan update tahunan; validasi silang untuk produk di Kalimantan
Witjes et al. (2022) PeerJ	Klasifikasi land cover temporal di Eropa menggunakan	RF, XGBoost; Spatial Block CV (spacv package); fitur	Sentinel-2 annual composite; Eropa	XGBoost sedikit lebih baik dari RF dalam SBCV	Metodologi komparatif RF vs XGBoost dengan SBCV

Peneliti (Tahun)	Tujuan Penelitian	Metode	Dataset & Lokasi	Algoritma Terbaik	Relevansi dengan Penelitian Ini
	Sentinel-2 time series dengan pendekatan Spatial Block CV dan ML ensemble	temporal statistik (median, IQR) per band	Tengah; 8 kelas tutupan lahan		yang sangat relevan; penelitian ini mengadaptasi untuk konteks Kalimantan tropika
Stanimirova et al. (2023) Remote Sensing	Validasi ESA WorldCover 2020 dan 2021 di berbagai bioma dengan fokus akurasi kelas-kelas spesifik	Accuracy assessment; stratified random sampling; confusion matrix; OA, User's & Producer's Accuracy	ESA WorldCover 2020/2021; Global, termasuk kawasan tropis Asia Tenggara	OA global ~76% (2020), ~74% (2021)	Dasar pemahaman tentang kualitas dan keterbatasan ESA WorldCover sebagai label training dalam penelitian ini

2.12 Gap Penelitian dan Kontribusi

Berdasarkan tinjauan penelitian terdahulu yang telah dipaparkan, dapat diidentifikasi beberapa gap penelitian yang signifikan. Pertama, belum ada penelitian yang secara eksplisit mengintegrasikan analisis dual-driver dalam satu kerangka penelitian tutupan lahan Kalimantan: selama ini, penelitian tentang deforestasi Kalimantan cenderung fokus pada satu driver (sawit, atau pertambangan, atau urbanisasi), sementara dampak IKN terhadap tutupan lahan baru mulai diteliti secara terbatas. Kedua, penelitian-penelitian komparatif ML untuk land cover classification di wilayah tropis Kalimantan yang menggunakan Spatial Block CV—bukan random CV—masih sangat terbatas, sehingga estimasi akurasi yang dilaporkan dalam literatur sebelumnya mungkin bersifat optimistis. Ketiga, penerapan SHAP interpretability untuk memahami kontribusi fitur spektral dan lingkungan dalam klasifikasi tutupan lahan Kalimantan belum didokumentasikan secara sistematis.

Kontribusi penelitian ini terhadap literatur dan kebijakan dapat dirangkum sebagai berikut:

1. Integrasi analisis dual-driver IKN dan ekspansi pertambangan dalam satu framework klasifikasi tutupan lahan multitemporal Kalimantan yang belum dilakukan dalam penelitian sebelumnya.
2. Penerapan Spatial Block Cross Validation untuk evaluasi model klasifikasi tutupan lahan Kalimantan, menghasilkan estimasi akurasi yang lebih realistis dibandingkan pendekatan random CV.
3. Analisis interpretabilitas model berbasis SHAP untuk memahami kontribusi fitur spektral Sentinel-2 dalam klasifikasi tutupan lahan hutan tropis Kalimantan.
4. Komparasi komprehensif enam algoritma supervised machine learning (RF, XGBoost, LightGBM, LR, SVM, MLP) dalam konteks klasifikasi tutupan lahan Kalimantan berbasis Sentinel-2.
5. Pengembangan dashboard/web GIS interaktif yang menyajikan hasil analisis multitemporal, change detection, dan hotspot secara terpadu dan dapat diakses publik.
6. Peta dasar transformasi tutupan lahan Kalimantan 2018–2024 pada resolusi 10 meter yang dapat dimanfaatkan sebagai referensi untuk perencanaan tata ruang dan pemantauan lingkungan.

2.13 Kerangka Penelitian

Kerangka penelitian ini dibangun atas dasar hubungan logis antara permasalahan, data, metode, dan output yang dihasilkan. Secara konseptual, penelitian ini berangkat dari identifikasi dua driver utama perubahan tutupan lahan di Kalimantan—pembangunan IKN dan ekspansi pertambangan/bare land—yang menimbulkan kebutuhan akan pemantauan spasial multitemporal yang sistematis dan akurat.

Data utama yang digunakan adalah citra Sentinel-2 SR Harmonized periode 2018–2024 yang diakses melalui GEE, dilengkapi dengan data pendukung berupa ESA WorldCover 2021 (label training), SRTM (topografi), CHIRPS (curah hujan), dan jarak terhadap kawasan IKN (distance raster). Preprocessing dilakukan seluruhnya di GEE mencakup cloud masking, perhitungan indeks spektral, dan pembuatan median composite tahunan. Selanjutnya, fitur-fitur tersebut digunakan untuk melatih dan mengevaluasi enam algoritma machine learning dengan evaluasi berbasis Spatial Block CV. Model terbaik

digunakan untuk menghasilkan peta tutupan lahan tahunan (2018–2024), yang kemudian dianalisis menggunakan post-classification comparison untuk mendeteksi perubahan dan transisi. Analisis SHAP dilakukan untuk menginterpretasikan model terbaik, dan seluruh hasil divisualisasikan dalam dashboard interaktif.

III. METODOLOGI PENELITIAN

Penelitian ini menggunakan framework Cross-Industry Standard Process for Data Mining (CRISP-DM) sebagai kerangka metodologi utama. CRISP-DM merupakan standar de facto dalam proses data mining dan machine learning yang terdiri dari enam fase yang bersifat iteratif: Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, dan Deployment. Pemilihan CRISP-DM sebagai framework metodologi didasarkan pada sifatnya yang sistematis, iteratif, dan berorientasi pada output yang dapat digunakan (deployable results), yang sangat sesuai dengan tujuan penelitian ini yang menghasilkan model klasifikasi yang diimplementasikan dalam dashboard web.

3.1 Business Understanding

Fase Business Understanding bertujuan untuk mendefinisikan permasalahan penelitian secara operasional dalam konteks kebutuhan informasi yang nyata. Permasalahan inti yang dihadapi adalah ketidaktersediaan peta tutupan lahan multitemporal Kalimantan yang akurat dan mudah diakses untuk periode 2018–2024, padahal informasi tersebut sangat dibutuhkan untuk memantau dampak pembangunan IKN dan ekspansi pertambangan terhadap ekosistem hutan tropis. Ketiadaan informasi ini menciptakan gap yang serius dalam pengambilan keputusan berbasis bukti terkait perencanaan tata ruang, pengelolaan lingkungan, dan kebijakan kehutanan.

Tujuan data mining (data mining goal) yang ditetapkan adalah: (1) membangun model klasifikasi tutupan lahan dengan akurasi Overall Accuracy minimal 85% dan Cohen Kappa minimal 0.80 menggunakan evaluasi Spatial Block CV; (2) menghasilkan peta tutupan lahan tahunan untuk tahun 2018, 2020, 2022, dan 2024; (3) mendeteksi dan mengkuantifikasi perubahan tutupan lahan menggunakan post-classification comparison; dan (4) mengidentifikasi hotspot perubahan yang berkaitan dengan driver IKN dan pertambangan. Kriteria keberhasilan proyek ditetapkan berdasarkan threshold akurasi tersebut serta kualitas visualisasi dashboard yang dihasilkan.

Dalam fase ini juga dilakukan inventarisasi sumber daya yang tersedia: akses ke Google Earth Engine melalui akun penelitian, kapabilitas komputasi Python (scikit-learn, XGBoost, LightGBM, SHAP) di lingkungan lokal atau cloud (Google Colab), serta kemampuan pengembangan web menggunakan Streamlit atau React. Risiko yang

diidentifikasi mencakup potensi tutupan awan yang tinggi di beberapa periode (khususnya musim basah), ketidakakuratan label ESA WorldCover untuk kelas-kelas tertentu di konteks lokal, dan keterbatasan data ground truth untuk validasi independen.

3.2 Data Understanding

3.2.1 Sumber dan Karakteristik Data

Data yang digunakan dalam penelitian ini dapat dikelompokkan menjadi data utama dan data pendukung. Berikut disajikan ringkasan sumber data:

Nama Data	Sumber / Platform	Periode / Versi	Resolusi Spasial	Pemanfaatan dalam Penelitian
Sentinel-2 SR Harmonized	Google Earth Engine (COPERNICUS/S2_SR_HARMONIZED)	2018–2024 (annual composites)	10–20 meter	Fitur utama klasifikasi tutupan lahan dan change detection
ESA WorldCover 2021	Google Earth Engine (ESA/WorldCover/v200)	Versi 2021 (data tahun 2021)	10 meter	Label kelas tutupan lahan untuk training dan validasi awal
SRTM Digital Elevation	Google Earth Engine (USGS/SRTMGL1_003)	Akuisisi 2000 (statis)	30 meter	Fitur topografi: elevasi, slope, aspect
CHIRPS Rainfall	Google Earth Engine (UCSB-CHG/CHIRPS/DAILY)	2018–2024 (annual mean)	5.566 km	Fitur iklim: curah hujan rata-rata tahunan sebagai kovariat
Distance to IKN Centroid	Dihitung dari titik pusat KIPP IKN (GEE computation)	Statis	10 meter	Fitur spatial proximity: jarak piksel ke kawasan inti IKN
Mining Concession Proxy (Bare	Turunan BSI/NDVI komposit + data perizinan ESDM (opsional/untuk validasi)	2018–2024	10–20 meter	Proxy bare land untuk identifikasi area potensi pertambangan

Nama Data	Sumber / Platform	Periode / Versi	Resolusi Spasial	Pemanfaatan dalam Penelitian
Land Indicator)				

3.2.2 Eksplorasi Awal Data

Eksplorasi awal data dilakukan untuk memahami karakteristik koleksi citra Sentinel-2 di Kalimantan. Aspek yang dieksplorasi meliputi distribusi cloud cover per bulan untuk mengidentifikasi periode paling optimal untuk pembuatan komposit, jumlah scene yang tersedia per tahun per path/row, distribusi nilai reflektansi per band untuk kelas tutupan lahan utama (berdasarkan ESA WorldCover sebagai referensi awal), dan tingkat keseimbangan kelas (class imbalance) dalam dataset. Eksplorasi ini penting untuk menginformasikan keputusan metodologis selanjutnya, seperti strategi pembuatan komposit dan strategi oversampling/undersampling jika class imbalance terdeteksi parah.

Dari eksplorasi awal, diidentifikasi bahwa bulan-bulan dengan tutupan awan rendah di Kalimantan umumnya terjadi pada periode Agustus–Oktober (musim kemarau), sementara Desember–Februari memiliki tutupan awan sangat tinggi. Untuk analisis multitemporal, pendekatan median composite berbasis data sepanjang tahun digunakan untuk meminimalkan pengaruh tutupan awan, dengan pembobotan lebih ke periode musim kemarau jika diperlukan. Distribusi kelas ESA WorldCover di Kalimantan didominasi oleh Tree Cover (~60%), diikuti Cropland (~15%), Bare/Sparse Vegetation (~8%), Built-up (~5%), dan kelas-kelas lainnya. Ketidakseimbangan kelas ini perlu ditangani dalam strategi sampling dan pemilihan metrik evaluasi.

3.3 Data Preparation

3.3.1 Cloud Masking dan Penyaringan Citra

Preprocessing citra Sentinel-2 dilakukan sepenuhnya di Google Earth Engine. Langkah pertama adalah penyaringan koleksi Sentinel-2 SR Harmonized berdasarkan: (1) bounding box Pulau Kalimantan; (2) rentang waktu sesuai tahun yang dianalisis; dan (3) cloud cover percentage $\leq 30\%$ berdasarkan metadata property

'CLOUDY_PIXEL_PERCENTAGE'. Cloud masking selanjutnya dilakukan menggunakan band QA60 yang menyediakan bit flag untuk piksel awan opak (bit 10) dan awan tipis/cirrus (bit 11). Piksel yang ditandai sebagai awan di salah satu atau kedua bit tersebut dimasking (nilai diset menjadi NoData). Selain cloud mask dari QA60, dilakukan juga masking menggunakan band SCL (Scene Classification Layer) yang tersedia dalam produk Sentinel-2 Level-2A, dengan mengeksklusi piksel yang diklasifikasikan sebagai: 0 (No data), 1 (Saturated/Defective), 3 (Cloud Shadows), 8 (Cloud Medium Probability), 9 (Cloud High Probability), dan 10 (Thin Cirrus).

3.3.2 Pembuatan Median Composite Tahunan

Setelah cloud masking, dibuat median composite tahunan untuk setiap tahun dalam periode penelitian (2018, 2019, 2020, 2021, 2022, 2023, 2024). Namun, untuk analisis perubahan (change detection), peta tutupan lahan dibuat untuk periode representatif 2018, 2020, 2022, dan 2024 agar analisis temporal lebih terarah dan mengurangi beban komputasi. Median composite dipilih dibandingkan mean composite karena lebih robust terhadap nilai ekstrem yang mungkin masih tersisa setelah cloud masking (seperti bayangan awan yang lolos dari deteksi atau nilai saturasi). Median composite dihitung per piksel di seluruh koleksi scene yang tersedia untuk setiap tahun. Untuk Kalimantan yang merupakan wilayah tropis dengan tutupan awan tinggi, pendekatan komposit ini menghasilkan gambar 'pseudo clear-sky' yang merepresentasikan kondisi vegetasi tipikal sepanjang tahun.

3.3.3 Perhitungan Indeks Spektral

Setelah pembuatan median composite, dihitung empat indeks spektral turunan untuk setiap tahun:

NDVI (Normalized Difference Vegetation Index): dihitung dari band B8 (NIR) dan B4 (Red) dengan formula $(B8 - B4) / (B8 + B4)$. NDVI merupakan indeks paling umum untuk mengukur kerapatan vegetasi dan kesehatan tanaman. Nilai NDVI berkisar dari -1 hingga +1, di mana nilai > 0.3 umumnya mengindikasikan tutupan vegetasi.

NDBI (Normalized Difference Built-up Index): dihitung dari band B11 (SWIR1) dan B8 (NIR) dengan formula $(B11 - B8) / (B11 + B8)$. NDBI positif mengindikasikan area terbangun karena SWIR tinggi pada material bangunan dan aspal, sementara NIR tinggi pada vegetasi.

NDMI (Normalized Difference Moisture Index): dihitung dari band B8 (NIR) dan B11 (SWIR1) dengan formula $(B8 - B11) / (B8 + B11)$. NDMI sensitif terhadap kandungan air vegetasi dan kondisi kelembaban permukaan, berguna untuk membedakan hutan primer, hutan sekunder, dan perkebunan.

BSI (Bare Soil Index): dihitung dari kombinasi band B11 (SWIR1), B4 (Red), B8 (NIR), dan B2 (Blue) dengan formula $((B11 + B4) - (B8 + B2)) / ((B11 + B4) + (B8 + B2))$. BSI tinggi mengindikasikan lahan terbuka tanpa vegetasi, sangat relevan untuk mendeteksi area pertambangan aktif, bekas tambang, dan lahan konstruksi.

3.3.4 Integrasi Fitur Pendukung

Selain fitur spektral dari Sentinel-2, fitur pendukung berikut diintegrasikan ke dalam stack fitur:

Topografi (SRTM): Elevasi, slope (kemiringan lereng dalam derajat), dan aspect (arah hadap lereng) dihitung dari Digital Elevation Model SRTM resolusi 30 meter. Fitur topografi penting untuk membedakan vegetasi dataran rendah dan pegunungan, serta untuk membedakan sawah (cenderung di dataran rendah) dari hutan pegunungan.

Curah Hujan (CHIRPS): Mean curah hujan tahunan dihitung dari data CHIRPS daily untuk setiap tahun analisis. Curah hujan mempengaruhi komposisi vegetasi dan aktivitas pertanian, sehingga dapat meningkatkan diskriminasi antar kelas tutupan lahan.

Distance to IKN: Jarak Euclidean dari setiap piksel ke centroid Kawasan Inti Pusat Pemerintahan (KIPP) IKN dihitung sebagai fitur spasial eksplisit. Fitur ini digunakan dalam analisis SHAP untuk memahami sejauh mana kedekatan dengan IKN berkontribusi terhadap probabilitas prediksi kelas tertentu (seperti Built-up atau Bare).

3.3.5 Sampling Titik Training dan Testing

Titik sampel untuk training dan testing diambil melalui stratified random sampling berbasis peta ESA WorldCover 2021, dengan jumlah sampel yang proporsional terhadap luas kelas (namun dengan minimum sampel per kelas sebesar 500 titik untuk kelas-kelas minor). Kelas tutupan lahan yang digunakan dalam penelitian ini diadaptasi dari skema ESA WorldCover dan dikondensasi menjadi tujuh kelas utama yang relevan untuk konteks Kalimantan: (1) Hutan/Tree Cover, (2) Semak/Shrubland, (3) Lahan Pertanian/Cropland, (4) Lahan Terbangun/Built-up, (5) Lahan Terbuka/Bare Land, (6) Badan Air/Water, dan (7) Lahan Basah/Wetland (termasuk mangrove). Untuk setiap titik sampel, nilai fitur dari

semua band Sentinel-2 dan indeks turunannya diekstraksi dari median composite yang sesuai. Total dataset sampel diestimasi sekitar 20.000–30.000 titik untuk memastikan keterwakilan spasial yang memadai di seluruh Kalimantan.

3.4 Modeling

3.4.1 Konfigurasi dan Alasan Pemilihan Algoritma

Enam algoritma supervised machine learning dipilih untuk dibandingkan dalam penelitian ini, dengan pertimbangan yang mencakup aspek performa, interpretabilitas, kompleksitas komputasi, dan representasi kategori algoritma:

Random Forest (RF): Dipilih sebagai baseline ensemble yang telah terbukti sangat efektif untuk klasifikasi tutupan lahan dalam banyak studi. RF diimplementasikan menggunakan scikit-learn dengan hiperparameter awal: `n_estimators=200`, `max_features='sqrt'`, dan `class_weight='balanced'` untuk menangani class imbalance. RF juga menghasilkan feature importance berbasis impurity yang dapat dikomparasi dengan SHAP values.

XGBoost: Dipilih sebagai representasi gradient boosting dengan regularisasi yang kuat. XGBoost diimplementasikan dengan hiperparameter awal: `n_estimators=300`, `max_depth=6`, `learning_rate=0.1`, dan `scale_pos_weight` untuk menangani class imbalance. XGBoost mendukung SHAP values secara native melalui TreeSHAP.

LightGBM: Dipilih karena kecepatan komputasinya yang superior dibandingkan XGBoost, sangat relevan mengingat ukuran dataset yang besar. LightGBM diimplementasikan dengan hiperparameter awal: `n_estimators=500`, `learning_rate=0.05`, `num_leaves=63`, `min_child_samples=20`, dan `class_weight='balanced'`. LightGBM juga mendukung TreeSHAP untuk interpretabilitas.

Logistic Regression (LR): Dipilih sebagai baseline linier yang interpretatif dan komputasional efisien. LR diimplementasikan sebagai One-vs-Rest (OvR) multi-class dengan regularisasi L2 (Ridge) dan solver 'lbfgs'. Performa LR yang lebih rendah dibandingkan ensemble methods diharapkan dapat memperjelas nilai tambah dari algoritma yang lebih kompleks.

Support Vector Machine (SVM): Dipilih untuk representasi margin-based classifier yang efektif di ruang dimensi tinggi. Mengingat kompleksitas komputasi SVM yang $O(n^3)$ untuk training, SVM diimplementasikan menggunakan kernel RBF dengan subset sampling (maksimum 10.000 sampel training) jika dataset terlalu besar. Hiperparameter C dan gamma dioptimalkan menggunakan cross-validation terbatas.

Multilayer Perceptron (MLP): Dipilih sebagai representasi neural network sederhana untuk memahami apakah arsitektur network memberikan keunggulan atas ensemble methods. MLP diimplementasikan dengan arsitektur (256, 128, 64) neurons, fungsi aktivasi ReLU, regularisasi L2 ($\alpha=0.001$), early stopping berbasis validation loss, dan maksimum 200 epoch.

3.4.2 Optimasi Hiperparameter

Optimasi hiperparameter dilakukan menggunakan Randomized Search Cross Validation (RandomizedSearchCV dari scikit-learn) dengan 3-fold spatial block CV sebagai inner CV loop. Pendekatan nested cross-validation ini memastikan bahwa estimasi akurasi yang dilaporkan tidak terpengaruh oleh optimisme yang berasal dari pemilihan hiperparameter. Ruang pencarian hiperparameter dibatasi pada parameter-parameter yang paling berpengaruh berdasarkan literatur, dengan jumlah iterasi randomized search sebesar 50 per algoritma untuk menyeimbangkan kelengkapan pencarian dengan efisiensi komputasi.

3.4.3 Penanganan Ketidakseimbangan Kelas

Ketidakseimbangan kelas (class imbalance) merupakan tantangan nyata dalam dataset tutupan lahan Kalimantan mengingat dominasi kelas Hutan/Tree Cover. Strategi penanganan yang diterapkan meliputi: (1) penggunaan parameter `class_weight='balanced'` untuk algoritma yang mendukungnya (RF, LR, MLP, SVM); (2) penggunaan skala bobot invers frekuensi untuk XGBoost dan LightGBM; dan (3) evaluasi berbasis F1 Macro yang memberikan bobot setara pada semua kelas terlepas dari frekuensinya. Strategi SMOTE (Synthetic Minority Oversampling Technique) dipertimbangkan sebagai alternatif jika class imbalance terlalu parah, namun tidak diterapkan pada data spasial karena potensi menciptakan sampel sintetis yang tidak realistis secara geografis.

3.5 Evaluation

3.5.1 Spatial Block Cross Validation

Spatial Block Cross Validation (SBCV) diimplementasikan menggunakan library 'spatial-blocks' atau implementasi kustom berbasis clustering spasial. Langkah pertama adalah menentukan ukuran blok spasial yang sesuai berdasarkan estimasi spasial autocorrelation range dari data, menggunakan analisis semivariogram pada sampel training. Ukuran blok yang terlalu kecil akan menyebabkan spatial leakage, sementara ukuran yang terlalu besar akan mengurangi jumlah fold yang tersedia dan meningkatkan varians estimasi. Berdasarkan literatur untuk data tutupan lahan resolusi menengah di wilayah tropis, ukuran blok 50–100 km² diestimasi sebagai range yang wajar, namun akan disesuaikan berdasarkan analisis semivariogram aktual.

Dataset sampel dibagi menjadi 5 blok spasial menggunakan k-means clustering pada koordinat geografis. Setiap iterasi CV menggunakan 4 blok untuk training dan 1 blok untuk validation, menghasilkan 5 fold dengan blok geografis yang berbeda sebagai validation set. Penting dicatat bahwa blok-blok ini diterapkan secara konsisten di seluruh algoritma untuk memastikan perbandingan yang adil.

3.5.2 Metrik Evaluasi

Evaluasi performa model menggunakan serangkaian metrik yang komprehensif untuk memastikan penilaian yang menyeluruh:

Overall Accuracy (OA): Proporsi total piksel yang diklasifikasikan dengan benar dari seluruh sampel validasi. OA memberikan gambaran umum tentang akurasi model namun sensitif terhadap class imbalance.

F1 Macro: Rata-rata tidak terbobot dari F1-score per kelas. F1-score per kelas adalah harmonic mean dari Precision dan Recall untuk kelas tersebut. F1 Macro memberikan representasi yang lebih adil terhadap performa pada semua kelas terlepas dari ukurannya.

Cohen Kappa: Metrik yang mengukur kesepakatan antara prediksi dan label sebenarnya, setelah dikoreksi untuk probabilitas kesepakatan secara kebetulan. Kappa > 0.8 umumnya dianggap sebagai 'almost perfect agreement' dalam literatur pemetaan tutupan lahan.

IoU per Kelas (Intersection over Union): Metrik yang mengukur overlap antara piksel yang diprediksi sebagai kelas k dan piksel aktual kelas k , dihitung sebagai $TP / (TP$

+ FP + FN). IoU per kelas memberikan informasi tentang performa model pada setiap kelas secara individual.

Producer's Accuracy (PA) dan User's Accuracy (UA): PA mengukur proporsi piksel aktual kelas k yang berhasil diklasifikasikan dengan benar (= Recall), sedangkan UA mengukur proporsi piksel yang diklasifikasikan sebagai kelas k yang memang benar kelas k (= Precision). Keduanya disajikan dalam confusion matrix lengkap.

Confusion Matrix: Matriks $n \times n$ (n = jumlah kelas) yang menyajikan detail distribusi prediksi untuk setiap kelas aktual, memungkinkan identifikasi pasangan kelas yang sering tertukar (class confusion).

3.5.3 Target Akurasi

Berdasarkan review literatur untuk klasifikasi tutupan lahan berbasis Sentinel-2 di wilayah tropis dengan evaluasi SBCV yang lebih ketat, target akurasi yang ditetapkan adalah: $OA \geq 80\%$, $Cohen\ Kappa \geq 0.75$, dan $F1\ Macro \geq 0.75$. Target ini lebih konservatif dibandingkan nilai-nilai yang sering dilaporkan dalam penelitian yang menggunakan random CV, yang mencerminkan ekspektasi realistis untuk evaluasi berbasis SBCV.

3.6 Change Detection

3.6.1 Post-Classification Comparison

Change detection dilakukan menggunakan metode Post-Classification Comparison (PCC) yang membandingkan peta tutupan lahan dari empat titik waktu: 2018, 2020, 2022, dan 2024. Untuk setiap pasangan titik waktu, dibuat binary change/no-change map dan categorical transition map. Categorical transition map menunjukkan untuk setiap piksel: kelas asal pada t_1 dan kelas tujuan pada t_2 , menghasilkan n^2 kemungkinan transisi untuk n kelas. Transisi yang secara ekologis tidak mungkin atau tidak realistis (misalnya perubahan dari Water menjadi Hutan dalam 2 tahun) diidentifikasi dan diperiksa secara manual sebagai quality check untuk kesalahan klasifikasi.

3.6.2 Transition Matrix dan Analisis Perubahan

Transition matrix dihitung untuk setiap pasangan periode (2018→2020, 2020→2022, 2022→2024) dan untuk keseluruhan periode (2018→2024). Setiap elemen M_{ij} dalam matrix merepresentasikan luas area (dalam hektar atau km^2) yang bertransisi dari

kelas i ke kelas j . Dari matrix ini dapat dihitung: total luas yang tidak berubah (diagonal matrix), luas netto perubahan per kelas (jumlah baris dikurangi jumlah kolom, atau sebaliknya), luas total yang mengalami perubahan, dan persentase perubahan relatif terhadap luas awal setiap kelas.

Analisis spesifik yang dilakukan meliputi: (1) Kuantifikasi deforestasi—luas Hutan yang bertransisi ke kelas non-hutan (Cropland, Built-up, Bare Land) per periode; (2) Urban expansion—luas penambahan kelas Built-up dari kelas lain, dengan fokus di kawasan IKN; (3) Bare land expansion—luas penambahan kelas Bare/Sparse yang berkorelasi dengan lokasi konsesi pertambangan; dan (4) Revegetation—luas Bare Land atau Cropland yang bertransisi ke Shrubland atau Tree Cover (regenerasi alami atau reboisasi).

3.6.3 Hotspot Analysis

Untuk mengidentifikasi lokasi perubahan yang paling intensif, dilakukan hotspot analysis menggunakan Kernel Density Estimation (KDE) pada titik-titik pusat piksel yang mengalami perubahan. Hotspot IKN diidentifikasi dengan mengoverlay change map dengan buffer zones di sekitar kawasan inti IKN pada radius 5 km, 10 km, 20 km, dan 50 km. Hotspot pertambangan diidentifikasi dengan mengoverlay perubahan ke Bare Land dengan data batas konsesi pertambangan (jika tersedia) atau dengan analisis kepadatan perubahan di luar kawasan terbangun.

3.7 Interpretabilitas Model (SHAP Analysis)

Setelah model terbaik diidentifikasi berdasarkan hasil evaluasi SBCV, analisis SHAP dilakukan untuk memahami hubungan antara fitur input dan prediksi model. SHAP diimplementasikan menggunakan library shap (versi terbaru) dalam Python. Untuk model berbasis tree (RF, XGBoost, LightGBM), digunakan TreeExplainer yang menghitung exact SHAP values secara efisien. Untuk model non-tree (LR, SVM, MLP), digunakan KernelExplainer atau LinearExplainer sebagai pendekatan model-agnostic.

Analisis SHAP yang dilakukan mencakup: (1) Global feature importance—mean absolute SHAP value per fitur untuk menentukan fitur yang secara rata-rata paling berpengaruh terhadap prediksi; (2) SHAP summary plot—scatter plot yang menampilkan distribusi SHAP values untuk setiap fitur, diwarnai berdasarkan nilai fitur, memungkinkan identifikasi hubungan positif/negatif; (3) SHAP dependence plot—menampilkan hubungan

antara nilai satu fitur dan SHAP value-nya, dengan kemungkinan interaksi dengan fitur kedua; dan (4) Class-specific SHAP analysis—analisis SHAP untuk setiap kelas tutupan lahan secara terpisah, mengidentifikasi fitur-fitur yang paling membedakan kelas tersebut dari kelas lainnya.

Hasil analisis SHAP diinterpretasikan secara ekologis dan spektral: apakah NDVI memiliki SHAP value positif tinggi untuk kelas Hutan? Apakah BSI memiliki SHAP value positif untuk kelas Bare Land? Apakah NDBI berkorelasi positif dengan prediksi kelas Built-up? Interpretasi ini memvalidasi model secara kualitatif dan memberikan wawasan tentang separabilitas spektral kelas-kelas tutupan lahan di konteks hutan tropis Kalimantan.

3.8 Deployment: Dashboard Web GIS Interaktif

Tahap deployment bertujuan untuk mengemas hasil penelitian dalam bentuk yang dapat diakses dan digunakan oleh pemangku kepentingan yang lebih luas, tidak hanya kalangan akademis. Dashboard/web GIS interaktif dikembangkan menggunakan Streamlit (Python) atau React-based application sebagai frontend, dengan peta interaktif menggunakan Leaflet.js atau Folium.

Fitur-fitur utama yang diimplementasikan dalam dashboard meliputi:

- Land Cover Map Viewer: Visualisasi peta tutupan lahan untuk tahun yang dipilih pengguna (2018/2020/2022/2024) dengan legenda kelas yang jelas dan opsi untuk menampilkan/menyembunyikan layer tertentu.
- Temporal Slider: Kontrol interaktif untuk membandingkan peta tutupan lahan antara dua tahun berbeda secara side-by-side atau melalui swipe interface, memungkinkan visualisasi perubahan yang intuitif.
- Change Detection Map: Layer perubahan tutupan lahan yang dapat difilter berdasarkan tipe transisi (misalnya hanya menampilkan konversi hutan ke lahan terbangun, atau perluasan lahan terbuka).
- Hotspot Analysis Panel: Visualisasi konsentrasi spasial perubahan tutupan lahan menggunakan heatmap, dengan konteks layer tambahan berupa batas IKN dan kawasan konsesi pertambangan (jika data tersedia).

- Model Comparison Dashboard: Tabel dan grafik yang menyajikan perbandingan metrik akurasi (OA, F1 Macro, Kappa) dari keenam algoritma, serta radar chart untuk visualisasi kekuatan relatif masing-masing model.
- SHAP Visualization Panel: Tampilan interaktif dari SHAP summary plot dan dependence plot yang memungkinkan eksplorasi kontribusi fitur terhadap prediksi untuk masing-masing kelas tutupan lahan.
- Statistics Panel: Ringkasan statistik luas tutupan lahan per kelas per tahun, grafik tren perubahan luas (line chart), dan Sankey diagram untuk transition matrix yang menampilkan alur perpindahan antar kelas.

Dashboard ini akan di-deploy menggunakan layanan hosting gratis (Streamlit Cloud atau GitHub Pages) sehingga dapat diakses melalui browser tanpa instalasi software. Peta tutupan lahan yang telah diklasifikasikan akan diekspor dari GEE sebagai Cloud Optimized GeoTIFF (COG) yang dapat di-stream langsung ke browser menggunakan TiTiler atau layanan tile hosting, memastikan performa yang memadai untuk visualisasi peta skala Kalimantan.

DAFTAR PUSTAKA

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- Descals, A., Wich, S., Meijaard, E., Gaveau, D. L. A., Peedell, S., & Szantoi, Z. (2021). High-resolution global map of smallholder and industrial closed-canopy oil palm plantations. *Earth System Science Data*, 13(3), 1211–1231. <https://doi.org/10.5194/essd-13-1211-2021>
- Dong, J., Kuang, W., Liu, J., & Xiao, X. (2023). Annual maps of global artificial impervious area (GAIA) between 1985 and 2018. *Remote Sensing of Environment*, 236, 111510.
- ESA. (2021). ESA WorldCover 10m v200. European Space Agency. <https://doi.org/10.5281/zenodo.7254221>
- Fick, S. E., & Hijmans, R. J. (2017). WorldClim 2: New 1-km spatial resolution climate surfaces for global land areas. *International Journal of Climatology*, 37(12), 4302–4315.
- Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A., & Michaelsen, J. (2015). The climate hazards infrared precipitation with stations—A new environmental record for monitoring extremes. *Scientific Data*, 2(1), 150066. <https://doi.org/10.1038/sdata.2015.66>
- Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., & Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202, 18–27. <https://doi.org/10.1016/j.rse.2017.06.031>
- Hansen, M. C., Potapov, P. V., Moore, R., Hancher, M., Turubanova, S. A., Tyukavina, A., Thau, D., Stehman, S. V., Goetz, S. J., Loveland, T. R., Kommareddy, A., Egorov, A., Chini, L., Justice, C. O., & Townshend, J. R. G. (2013). High-resolution global maps of 21st-century forest cover change. *Science*, 342(6160), 850–853. <https://doi.org/10.1126/science.1244693>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS 2017)*, 3149–3157.
- Kuhn, S., & Cracknell, M. J. (2021). Geospatial machine learning: A review. *Remote Sensing*, 13(13), 2489.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56–67. <https://doi.org/10.1038/s42256-019-0138-9>

- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.
- Main-Knorn, M., Pflug, B., Louis, J., Debaecker, V., Müller-Wilm, U., & Gascon, F. (2017). Sen2Cor for Sentinel-2. *Proceedings of SPIE*, 10427, 1042704. <https://doi.org/10.1117/12.2278218>
- Pelletier, C., Webb, G. I., & Petitjean, F. (2019). Temporal convolutional neural network for the classification of satellite image time series. *Remote Sensing*, 11(5), 523.
- Phiri, D., Simwanda, M., Salekin, S., Nyirenda, V. R., Murayama, Y., & Ranagalage, M. (2021). Sentinel-2 data for land use and land cover mapping: A review. *Remote Sensing*, 12(14), 2291.
- Rouse, J. W., Haas, R. H., Schell, J. A., & Deering, D. W. (1974). Monitoring vegetation systems in the Great Plains with ERTS. *Proceedings of the Third ERTS Symposium*, 1, 309–317.
- Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Aroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929. <https://doi.org/10.1111/ecog.02881>
- Stanimirova, R., Tarrio, K., Turlej, K., McAvoy, K., Stonebrook, S., Hu, K.-T., Arévalo, P., Bullock, E. L., Zhang, Y., Woodcock, C. E., Olofsson, P., Zhu, Z., Barber, C. P., Souza, C., Chen, S., Wang, J. A., Mensah, F., Calderón-Loor, M., Hadjikakou, M., ... Friedl, M. A. (2023). A global land cover training dataset from 1984 to 2020. *Scientific Data*, 10(1), 879.
- Tobler, W. R. (1970). A computer movie simulating urban growth in the Detroit region. *Economic Geography*, 46(sup1), 234–240.
- Undang-Undang Republik Indonesia Nomor 3 Tahun 2022 tentang Ibu Kota Negara. Lembaran Negara Republik Indonesia Tahun 2022 Nomor 41.
- Valavi, R., Elith, J., Lahoz-Monfort, J. J., & Guillera-Aroita, G. (2019). blockCV: An r package for generating spatially or environmentally separated folds for k-fold cross-validation of species distribution models. *Methods in Ecology and Evolution*, 10(2), 225–232. <https://doi.org/10.1111/2041-210X.13107>
- Vermote, E., Roger, J. C., Franch, B., & Masek, J. G. (2018). A long term approach for land surface reflectance retrieval from Landsat and Sentinel-2 (Invited). *Remote Sensing of Environment*, 220, 444–457.
- Witjes, M., Parente, L., van Diemen, C. J., Hengl, T., Ideesink, P., Lopes, M., Boogaard, H., de Wit, A., Walvoort, D., & Appelhans, T. (2022). A spatiotemporal ensemble machine learning framework for generating land use/land cover time-series maps for Europe (2000–2019) based on LUCAS, CORINE and GLAD Landsat. *PeerJ*, 10, e13573.

- Zha, Y., Gao, J., & Ni, S. (2003). Use of normalized difference built-up index in automatically mapping urban areas from TM imagery. *International Journal of Remote Sensing*, 24(3), 583–594.
- Zhao, H., & Chen, X. (2005). Use of normalized difference bareness index in quickly mapping bare areas from TM/ETM+. *International Geoscience and Remote Sensing Symposium*, 3, 1666–1668.