

Analisis Perubahan Substrat Bentik Terumbu Karang Akibat *El Niño-Southern Oscillation* Menggunakan *Clustering Multitemporal* dengan *Citra Sentinel-2A*

Studi Kasus Pulau Karimunjawa

Kelompok 5 (3SI1)

Dosen Pengampu Mata Kuliah: Robert Kurniawan, S.S.T., M.Si.

Ringkasan— Terumbu karang Kepulauan Karimunjawa menghadapi ancaman serius akibat fenomena *El Niño-Southern Oscillation* (ENSO) 2023 yang memicu peristiwa pemutihan karang global keempat (*4th Global Coral Bleaching Event*). Penelitian ini mengusulkan pendekatan *multitemporal clustering* berbasis citra *Sentinel-2A* untuk menganalisis perubahan substrat bentik terumbu karang akibat *El Niño* 2023–2024. Enam algoritma *unsupervised learning* dibandingkan, yaitu *K-Means*, *Gaussian Mixture Model* (GMM), *DBSCAN*, *OPTICS*, *Agglomerative Clustering*, dan *Spectral Clustering*, yang diintegrasikan dengan metode *Post-Classification Comparison* (PCC) untuk menghasilkan peta perubahan substrat. Fitur spektral yang digunakan meliputi Band B2, B3, B4 serta indeks *Depth Invariant Index* (DII), dengan reduksi dimensi menggunakan *Principal Component Analysis* (PCA). Evaluasi dilakukan secara intrinsik melalui *Silhouette Score* dan *Davies-Bouldin Index*, serta secara ekstrinsik menggunakan *Overall Accuracy* dan *Kappa Coefficient* berbasis *Allen Coral Atlas* (ACA) sebagai *ground truth*. Hasil penelitian divisualisasikan dalam bentuk *Change Detection Map* dan *Web Story Map* interaktif.

Kata Kunci— Terumbu karang, ENSO, clustering multitemporal, *Sentinel-2A*, substrat bentik, Karimunjawa.

I. PENDAHULUAN

1.1 Latar Belakang

Terumbu karang merupakan ekosistem laut dangkal yang memiliki nilai ekologis dan ekonomis tinggi karena menopang sekitar 25% seluruh kehidupan laut dunia [1], meskipun luasnya mencakup kurang dari 1% dasar laut global [2]. Sebagai bagian dari kawasan Segitiga Terumbu Karang (*Coral Triangle*), perairan Indonesia menjadi rumah bagi lebih dari 76% spesies karang keras dunia dan menopang penghidupan lebih dari 120 juta jiwa [3], dengan estimasi luas terumbu mencapai 51.000 km² [3]. Kepulauan Karimunjawa, sebagai salah satu Kawasan Konservasi Perairan (KKP) tertua di Indonesia, menjadi pusat keanekaragaman hayati dengan luas terumbu mencapai 132 km² [4]. Kawasan ini memiliki variasi morfologi yang kompleks, mencakup terumbu karang tepi (*fringing reefs*), terumbu pelat (*platform reefs*), hingga gosong karang (*coral cays*) [4], yang secara kolektif menyangga kehidupan bagi 9.000 penduduk lokal [3].

Namun, terumbu karang Karimunjawa menghadapi ancaman dari fenomena *El Niño-Southern Oscillation* (ENSO) yang memicu pemanasan suhu permukaan laut secara ekstrem [3]. Kawasan ini diprediksi memanaskan lebih cepat dibandingkan wilayah sekitarnya, sehingga menjadikannya sangat rentan terhadap kejadian pemutihan (*bleaching*) mengingat

sebelumnya sudah beberapa kali mengalami pemutihan besar akibat *El Niño* (1998, 2010, 2016). Pada peristiwa 2016, suhu air mencapai puncaknya di angka 30,5°C, mengakibatkan 88% karang terdampak secara negatif, di mana 27% memutih total dan 12% mengalami kematian [3].

Ancaman tersebut semakin diperparah seiring berkembangnya *El Niño* pada tahun 2023. Interaksi antara fenomena ini dengan anomali suhu laut yang tinggi memicu terjadinya *4th Global Coral Bleaching Event*, sebuah peristiwa pemutihan masif yang tercatat telah berdampak pada 87% wilayah terumbu karang secara global [5]. Fenomena ini berdampak signifikan pada perairan Indonesia sejak Juni 2023 hingga April 2024 [5]. Di Kepulauan Karimunjawa, anomali suhu permukaan laut tercatat meningkat drastis sebesar 2 - 3°C dengan nilai *Degree Heating Week* (DHW) mencapai 1 - 2°C per minggu [3]. Berdasarkan survei cepat pada awal 2024, tekanan termal ekstrem ini mengakibatkan pemutihan karang yang merata dari zona ratahan hingga lereng terumbu, dengan estimasi total persentase pemutihan mencapai 35% di seluruh kawasan [3].

Tekanan termal yang berulang ini tidak hanya menurunkan tutupan karang keras dari 29,2% menjadi 26,3%, tetapi juga mentransformasi komunitas bentik dari dominasi karang masif menuju karang bercabang (*branching*) dan *foliose* yang lebih rapuh [4]. Kepadatan karang kecil juga menurun signifikan dari 5,67 individu/m² pada 2013 menjadi 3,09 individu/m² pada 2022, yang mengindikasikan terhambatnya regenerasi alami [6]. Hilangnya kompleksitas substrat ini mengancam ketahanan pangan, pendapatan pariwisata, serta fungsi perlindungan pesisir dari bencana gelombang dan badai [4].

Kondisi tersebut menuntut adanya pemantauan perubahan substrat bentik secara multitemporal yang akurat dan efisien. Namun, metode survei lapangan konvensional memiliki keterbatasan jangkauan spasial untuk memantau kawasan kepulauan yang luas [7]. Sementara itu, citra satelit resolusi menengah seperti Landsat seringkali kurang memadai untuk mendelineasi fitur bentik yang heterogen [8]. Penggunaan citra *Sentinel-2A* dengan resolusi spasial 10 meter memungkinkan kapabilitas deteksi perubahan komunitas bentik yang jauh lebih baik [8] [7].

Berdasarkan kesenjangan tersebut, penelitian ini mengusulkan pendekatan multitemporal clustering berbasis citra *Sentinel-2A* untuk menganalisis perubahan substrat bentik terumbu karang di Karimunjawa akibat *El Niño* 2023. Kebaruan penelitian ini terletak pada integrasi analisis temporal periode sebelum (*pre*) dan sesudah (*post*) *El Niño* menggunakan algoritma clustering yang tidak memerlukan

data latih berlabel ekstensif. Pendekatan ini diharapkan mampu menghasilkan peta perubahan substrat yang kuantitatif untuk mendukung pengelolaan kawasan konservasi laut yang berkelanjutan.

1.2 Identifikasi Masalah

Berdasarkan latar belakang yang telah diuraikan sebelumnya, peneliti merangkum bahwa terdapat beberapa permasalahan yang teridentifikasi :

1. Belum adanya model pemetaan substrat bentik terumbu karang secara multitemporal di Karimun Jawa.
2. Belum dilakukan integrasi metode analisis dalam pemetaan dan analisis perubahan substrat bentik terumbu karang di Karimun Jawa.
3. Belum dilakukan evaluasi perbandingan untuk menentukan metode clustering yang paling optimal dalam mendukung analisis perubahan substrat bentik di Karimun Jawa.

1.3 Tujuan Penelitian

Berdasarkan latar belakang dan identifikasi masalah yang telah dipaparkan sebelumnya, tujuan penelitian ini adalah sebagai berikut :

1. Membangun model pemetaan substrat bentik terumbu karang secara multitemporal di Karimun Jawa menggunakan metode clustering berbasis citra Sentinel-2.
2. Mengintegrasikan metode clustering dengan Post-Classification Comparison (PCC) untuk menghasilkan peta perubahan substrat bentik terumbu karang di Karimun Jawa.
3. Membandingkan performa metode clustering untuk menentukan metode yang paling optimal dalam analisis perubahan substrat bentik di Karimun Jawa.
4. Mengevaluasi tingkat kesesuaian hasil clustering substrat bentik terhadap referensi Allen Coral Atlas (ACA) sebagai ground truth.

II. KAJIAN LITERATUR

2.1 Konsep dan Definisi

A. Ekosistem Terumbu Karang

Terumbu karang merupakan hasil sekresi dari karang yang berupa kalsium karbonat. Terumbu karang adalah struktur bawah laut yang dibentuk oleh koloni karang keras (*hard corals*). Meskipun hanya menutupi sekitar 0,2% dari dasar laut dunia, mereka menjadi rumah bagi 25–30% spesies laut yang diketahui. Selain menyediakan habitat kompleks bagi ribuan spesies, terumbu karang juga melindungi garis pantai dari abrasi, serta mendukung perikanan dan pariwisata yang bernilai miliaran dolar. Secara global, distribusi utama terumbu karang berada di perairan tropis, khususnya di kawasan *Coral Triangle*, yakni kawasan pusat keanekaragaman laut dunia, dengan Indonesia sebagai episentrumnya. Sebagai pemilik garis pantai terpanjang dan luas terumbu karang terbesar di

kawasan East Asian Seas (sekitar 50.000 km²), Indonesia menjadi rumah bagi 500 spesies karang serta ribuan jenis ikan.

Kondisi terumbu karang di Indonesia relatif lebih baik dibanding banyak kawasan lain. Hal ini terlihat dari peningkatan rata-rata tutupan karang keras di *East Asian Seas* dari 32,8% pada 1983 menjadi 36,8% pada 2019, dengan rasio karang terhadap alga sebesar 5:1 yang mencerminkan kesehatan ekosistem. Meskipun demikian, ancaman serius tetap mengintai, terutama fenomena pemutihan karang akibat suhu laut tinggi, penangkapan ikan destruktif, pencemaran darat, serta dampak jangka panjang dari perubahan iklim [9].

B. ENSO dan Dampaknya terhadap Terumbu Karang

Fenomena *El Niño-Southern Oscillation* (ENSO) merupakan interaksi atmosfer-samudra di Pasifik ekuatorial yang menjadi penggerak utama variabilitas iklim global. Menurut [10], anomali suhu permukaan laut (SPL) ini memicu perubahan sirkulasi udara yang berdampak luas melalui mekanisme telekoneksi. Di perairan Indonesia, pengaruh ini terlihat nyata melalui peningkatan suhu lokal dan penurunan produktivitas primer, seperti penurunan konsentrasi klorofil-a di Karimunjawa [11].

Peningkatan suhu laut yang drastis berdampak langsung pada kesehatan karang melalui mekanisme pemutihan (*coral bleaching*), yaitu kondisi lepasnya alga simbiotik dari jaringan polip karang. Untuk memantau risiko ini, NOAA Coral Reef Watch menggunakan metrik *Degree Heating Weeks* (DHW). Penelitian oleh [12] menunjukkan bahwa nilai DHW sebesar 4 hingga 8°C minggu merupakan ambang batas kritis terjadinya kematian massal. Risiko ini semakin mengkhawatirkan karena dunia kini mulai memasuki era pemutihan tahunan (*near-annual bleaching*) [5].

Dampak termal ini terbukti memiliki hubungan kausal dengan intensitas pemutihan pada skala individu terumbu [13]. Secara nasional, [14] mencatat bahwa *El Niño* 2016 di Sumatera Barat tidak hanya merombak struktur komunitas secara spasio-temporal, tetapi juga menghambat kepadatan rekrutmen karang juvenil. Temuan ini menegaskan bahwa gangguan ENSO menciptakan tekanan jangka panjang yang secara signifikan menghambat kemampuan regenerasi alami ekosistem terumbu karang.

C. Pengindraan Jauh untuk Monitoring Terumbu Karang

1. Konsep Dasar Pengindraan Jauh pada Ekosistem Laut

Pengindraan jauh pada ekosistem laut dangkal berfokus pada interaksi energi elektromagnetik dengan kolom air yang memiliki karakteristik fisik yang berbeda dengan daratan. Tantangan utama dalam perekaman spektral di perairan adalah fenomena atenuasi cahaya, yaitu proses penyerapan (*absorption*) dan hamburan (*scattering*) energi saat menembus air [15]. Spektrum merah terserap lebih cepat, sementara spektrum biru dan hijau mampu melakukan penetrasi lebih dalam. Hal ini menyebabkan intensitas pantulan objek dasar laut sangat dipengaruhi oleh kedalaman, sehingga nilai reflektansi pada sensor satelit memerlukan koreksi sebelum dianalisis.

2. Citra Satelit Sentinel-2A

Studi oleh [16] menunjukkan bahwa satelit Sentinel-2A melalui sensor *Multispectral Instrument* (MSI) menawarkan keunggulan signifikan dalam pemantauan terumbu karang melalui penyediaan data multispektral yang presisi. Dengan memanfaatkan pita spektrum tampak, yakni Band 2 (Biru), Band 3 (Hijau), dan Band 4 (Merah), yang memiliki resolusi spasial 10 meter, sensor ini mampu membedakan secara akurat karakteristik spektral bentos seperti karang hidup dan pasir di perairan dangkal. Keunggulan utama dari sensor ini terletak pada rasio antara resolusi spasial dan cakupan spektralnya yang memungkinkan identifikasi struktur ekosistem laut secara mendalam meskipun tanpa validasi lapangan yang luas. Selaras dengan kebutuhan tersebut, penelitian oleh [17], menunjukkan bahwa Google Earth Engine (GEE) sebagai platform akuisisi data utama dapat memfasilitasi penarikan koleksi citra Sentinel-2 secara masif melalui sistem komputasi awan, sehingga menyederhanakan alur kerja dari tahap pengumpulan hingga pemrosesan data spasio-temporal dalam jumlah besar.

3. Cloud Masking

Deteksi dan penghapusan tutupan awan merupakan tahap krusial dalam preprocessing citra optis multitemporal. Keberadaan awan dan bayangannya secara langsung mengontaminasi nilai reflektansi yang direkam sensor, sehingga dapat menghasilkan interpretasi substrat yang salah jika tidak dieliminasi [18]. Pada citra Sentinel-2A, proses cloud masking memanfaatkan metadata kualitas piksel yang tersedia dalam band QA60, yang mengklasifikasikan piksel berdasarkan probabilitas tutupan awan opak maupun awan tipis (cirrus). Dalam platform Google Earth Engine, masking dilakukan dengan menyaring piksel berdasarkan bit flag pada band tersebut, sehingga hanya piksel bebas awan yang dipertahankan untuk analisis lebih lanjut [17]. Pendekatan ini meningkatkan konsistensi nilai reflektansi spektral antar waktu, yang menjadi syarat utama dalam analisis multitemporal [19].

4. Normalized Difference Water Index (NDWI)

Normalized Difference Water Index (NDWI) merupakan indeks spektral yang dikembangkan oleh [20] yang dirancang untuk menonjolkan fitur perairan terbuka sekaligus menekan fitur daratan dan vegetasi terestrial. Indeks ini memanfaatkan perbedaan reflektansi yang signifikan antara pita spektrum hijau (*Green*) yang dipantulkan secara maksimal oleh air dan pita inframerah dekat (*Near-Infrared* atau NIR) yang diserap secara kuat oleh air. Secara matematis, NDWI diformulasikan sebagai berikut.

$$NDWI = \frac{GREEN - NIR}{GREEN + NIR} \quad (1)$$

Nilai NDWI berkisar antara -1 hingga 1. Nilai ini diinterpretasikan sebagai pemisah antara wilayah perairan dan daratan. Berdasarkan [20], piksel yang merepresentasikan fitur perairan umumnya menghasilkan nilai positif karena reflektansi hijau lebih tinggi dibanding NIR, sedangkan daratan

dan vegetasi cenderung bernilai nol atau negatif akibat dominasi reflektansi NIR.

Dalam konteks analisis citra pada daerah pesisir, NDWI diterapkan sebagai land mask untuk mengeliminasi piksel daratan sebelum masuk ke tahapan pemrosesan lanjutan. Hal ini memungkinkan peneliti fokus pada area perairan dan mencegah terjadinya distorsi data akibat adanya *noise* spektral dari objek darat yang dapat menurunkan akurasi.

5. Depth Invariant Index (DII)

metode *Depth Invariant Index* (DII) berdasarkan asumsi adanya hubungan linear antara logaritma reflektansi dari dua pita spektral yang berbeda pada jenis substrat yang sama di kedalaman [21]. Untuk mentransformasi nilai reflektansi menjadi indeks yang bebas dari pengaruh kedalaman, digunakan persamaan matematis sebagai berikut.

$$DII_{ij} = \ln(R_i) - \left[\frac{k_i}{k_j}\right] \ln(R_j) \quad (2)$$

Dengan keterangan R_i dan R_j merupakan nilai reflektansi pada pita i dan j , sementara k_i/k_j merupakan rasio koefisien atenuasi kolom air.

DII bekerja dengan mentransformasi data spektral ke dalam ruang koordinat baru yang bersifat independen terhadap variasi kedalaman vertikal. Menurut [15], melalui perhitungan rasio atenuasi, perbedaan nilai piksel yang terekam sensor dipaksa untuk hanya mencerminkan variasi tipe substrat secara horizontal. Hasilnya, piksel yang mewakili jenis substrat yang sama akan memiliki nilai DII yang seragam meskipun berada di kedalaman yang berbeda. dengan menggunakan DII, pemisahan antara habitat seperti karang hidup, lamun, dan pasir dapat dilakukan berdasarkan tanda spektral murni dari masing-masing substrat [22][15]. Hal ini secara signifikan meningkatkan keakuratan peta habitat yang dihasilkan, terutama pada wilayah perairan yang memiliki topografi dasar laut yang kompleks.

6. Principal Component Analysis

Principal Component Analysis (PCA) merupakan teknik transformasi linear yang merotasi sumbu data multispektral ke dalam sistem koordinat baru [23]. Tujuan utama dari transformasi ini adalah dekorelasi, yaitu proses menghilangkan hubungan atau redundansi informasi antar-band yang sering kali memiliki korelasi sangat kuat pada citra satelit. PCA menghasilkan komponen utama (*Principal Component*), dengan komponen pertama menangkap arah dengan variansi maksimal dari data asli.

Selain dekorelasi, PCA berperan krusial sebagai teknik reduksi dimensi yang memadatkan mayoritas variansi informasi dari berbagai pita spektral ke dalam beberapa komponen utama awal. Menurut [23], proses ini secara otomatis memisahkan sinyal informasi esensial dari gangguan sensor (*noise*) yang cenderung terisolasi pada komponen-komponen akhir. Sebagaimana diterapkan [16], pemanfaatan PCA sebelum tahap *clustering* terbukti meningkatkan stabilitas algoritma pengelompokan karena data yang diproses telah

bersih dari redundansi dan gangguan spektral, sehingga hasil kluster habitat menjadi lebih tajam dan akurat.

D. Unsupervised Learning pada Data Citra

1. K-Means Clustering

K-means clustering adalah metode yang digunakan untuk mengelompokkan data ke dalam beberapa kelompok (kluster) berdasarkan kedekatan jaraknya [24]. Misalnya, terdapat sekumpulan data sebanyak N yang masing-masing datanya memiliki d variabel (atau dimensi), yang ditulis sebagai $x_1, x_2, \dots, x_N$. Metode K-means akan membagi data tersebut menjadi k kelompok, dengan jumlah kelompok tidak melebihi jumlah data ($k \leq N$), yang dilambangkan $C_1, C_2, \dots, C_k$.

Tujuan utama dari K-means adalah membuat data dalam satu kelompok menjadi semirip mungkin satu sama lain. Caranya dengan meminimalkan nilai kesalahan yang disebut *within-cluster sum of squares* (WCSS), yaitu total dari kuadrat jarak antara setiap data dengan titik pusat (*centroid*) dari kelompoknya masing-masing. Semakin kecil nilai WCSS, semakin baik hasil pengelompokannya karena data dalam tiap kluster semakin dekat dengan pusatnya [16].

$$W(C_k) = \sum_{x_i \in C_k} (x_i - \mu_k)^2 \quad (3)$$

Dengan x_i adalah salah satu data yang termasuk ke dalam kluster C_k , sedangkan μ_k adalah nilai rata-rata (*centroid*) dari seluruh data yang ada di kluster C_k . Setiap data kemudian dimasukkan ke kluster tertentu dengan cara memilih kluster yang membuat jaraknya ke pusat kluster μ_k sekecil mungkin. Total kesalahan WCSS dihitung sebagai jumlah dari seluruh jarak kuadrat antara setiap data dan pusat kluster tempat data tersebut berada.

$$WCSS = \sum_{k=1}^k W(C_k) = \sum_{k=1}^k \sum_{x_i \in C_k} (x_i - \mu_k)^2 \quad (4)$$

Walaupun K-means clustering lebih umum digunakan pada data tabular, metode ini juga efektif untuk data citra, termasuk penginderaan jauh, untuk keperluan segmentasi citra, deteksi perubahan dan klasifikasi tutupan lahan [16].

2. Gaussian Mixture Model (GMM)

Gaussian Mixture Model (GMM) merupakan metode berbasis probabilitas yang mengasumsikan bahwa data terbentuk dari gabungan beberapa distribusi Gaussian. GMM memiliki tiga komponen utama, yaitu rata-rata (μ) sebagai pusat distribusi, kovarians (Σ) yang menggambarkan sebaran data, dan probabilitas campuran (π) yang menunjukkan bobot tiap distribusi, dengan total keseluruhannya bernilai 1.

$$\sum_{k=1}^k \pi_k = 1 \quad (5)$$

Jika dibandingkan dengan K-means yang cenderung menghasilkan kluster berbentuk bulat, GMM lebih fleksibel

karena mampu menangani bentuk kluster yang lebih kompleks seperti elips. Dalam bidang penginderaan jauh, GMM telah banyak dimanfaatkan untuk segmentasi citra, clustering, hingga pembuatan data sintetis [16].

3. Agglomerative Clustering

Agglomerative Clustering adalah salah satu metode *hierarchical clustering* yang bekerja dengan pendekatan *bottom-up*. Metode ini menganggap setiap titik data sebagai sebuah cluster tunggal, kemudian secara bertahap menggabungkan cluster yang paling mirip hingga terbentuk struktur hierarki berbentuk pohon atau dendrogram [25]. Penentuan kemiripan antar objek dalam tahap pengelompokan hierarki pada penelitian ini didasarkan pada perhitungan jarak Euclidean. Penggunaan metrik ini merujuk pada [23] yang menyatakan bahwa jarak Euclidean merupakan standar yang paling otoritatif untuk mengukur kedekatan antar piksel di dalam ruang spektral multispektral guna menentukan kemiripan tanda spektral substrat.

$$d = \sqrt{\sum_{i=1}^n (C_{1,i} - C_{2,i})^2} \quad (6)$$

Apabila $d < T$ (*threshold* jarak yang ditentukan pengguna), maka kedua kluster tersebut akan digabung.

Selain jarak antar titik, penelitian ini menerapkan Ward's Linkage sebagai kriteria pautan untuk menentukan jarak antar kluster. Pemilihan metode ini didasarkan pada prinsip [26] yang mengoptimalkan fungsi objektif dengan meminimalkan peningkatan total variansi di dalam kluster (*within-cluster variance*) pada setiap langkah penggabungan. Rumusnya didasarkan pada Error Sum of Squares (ESS).

$$d(A, B) = ESS_{AB} - (ESS_A + ESS_B) \quad (7)$$

Penggunaan Ward's Linkage sangat efektif dalam memproses data penginderaan jauh karena kemampuannya menangani gangguan (*noise*) sensor serta menghasilkan struktur kluster habitat yang lebih padat, seragam, dan terpisah secara tegas meskipun dalam lingkungan dasar laut yang memiliki kompleksitas variansi spektral yang tinggi [16][25].

Keunggulan metode ini adalah kemampuannya memberikan representasi hierarki yang jelas, sehingga hubungan antar data dapat divisualisasikan dengan baik. Selain itu, algoritma ini tidak memerlukan jumlah cluster ditentukan di awal, berbeda dengan metode seperti k-means. Namun, kelemahannya adalah kompleksitas komputasi yang relatif tinggi, terutama ketika jumlah data besar, serta sensitivitas terhadap pemilihan ukuran jarak atau linkage criteria [27].

4. Density-Based Spatial Clustering of Applications with Noise (DBSCAN)

DBSCAN merupakan algoritma clustering berbasis kepadatan yang mendefinisikan kelompok data sebagai area dengan konsentrasi titik tinggi yang dipisahkan oleh area dengan kepadatan rendah. Sebuah titik p dianggap berada dalam sebuah kluster jika kepadatan tetangganya memenuhi

ambang batas tertentu. Secara matematis, lingkungan- ϵ dari sebuah titik p didefinisikan sebagai himpunan titik q di dalam dataset D yang jaraknya terhadap p tidak melebihi radius ϵ [28].

$$N_\epsilon(p) = \{q \in D \mid \text{dist}(p, q) \leq \epsilon\} \quad (8)$$

Algoritma ini bekerja dengan dua parameter utama, yaitu ϵ (epsilon) sebagai radius pencarian tetangga, dan MinPts sebagai jumlah minimum titik dalam radius tersebut untuk membentuk sebuah cluster [28].

$$|N_\epsilon(p)| \geq \text{MinPts} \quad (9)$$

Keunggulan DBSCAN adalah kemampuannya menemukan cluster dengan bentuk yang tidak beraturan serta mengidentifikasi titik-titik yang dianggap sebagai noise atau outlier [29]. Berbeda dengan metode seperti k-means yang membutuhkan jumlah cluster ditentukan sejak awal, DBSCAN tidak memerlukan informasi tersebut sehingga lebih fleksibel untuk analisis data spasial maupun data berukuran besar. Namun, hasil clustering sangat bergantung pada pemilihan parameter ϵ dan MinPts , sehingga sensitivitas terhadap parameter ini menjadi salah satu keterbatasan DBSCAN [28].

5. Ordering Points To Identify the Clustering Structure (OPTICS)

Algoritma Ordering Points To Identify the Clustering Structure (OPTICS) merupakan pengembangan dari DBSCAN yang dibuat untuk mengatasi keterbatasan dalam penggunaan parameter jarak jangkauan global. Berbeda dengan DBSCAN yang langsung membentuk kluster, OPTICS bekerja dengan menyusun urutan data berdasarkan nilai *reachability distance* yang kemudian dapat divisualisasikan dalam bentuk *reachability plot*. Dengan cara ini, OPTICS mampu mengidentifikasi kluster dengan tingkat kepadatan yang berbeda-beda, sehingga lebih fleksibel dan efektif digunakan pada dataset yang memiliki variasi densitas. Ordering Points To Identify the Clustering Structure (OPTICS) merupakan algoritma pengelompokan berbasis densitas yang digunakan untuk mengeksplorasi struktur kluster dalam suatu dataset dengan membentuk urutan data yang disebut *cluster ordering*. Dalam prosesnya, OPTICS menggunakan dua konsep utama, yaitu *core distance* dan *reachability distance*, yang terus diperbarui untuk menyusun urutan spesifik dari setiap titik data. Pendekatan ini memungkinkan OPTICS memberikan gambaran yang lebih jelas mengenai struktur kluster, terutama pada data dengan variasi kepadatan yang berbeda [8].

6. Spectral Clustering

Spectral clustering adalah metode *clustering* berbasis teori graf spektral yang menggunakan matriks Laplacian untuk mengidentifikasi kelompok dalam data [30]. Metode ini

dimanfaatkan untuk mengelompokkan area berdasarkan karakteristik citra. *Spectral clustering* merupakan metode pengelompokan data yang memanfaatkan representasi graf untuk menggambarkan hubungan antar data. Pendekatan ini berakar pada *spectral theory* dan dikenal mampu mengidentifikasi struktur data yang kompleks secara efektif. Berbagai studi menunjukkan bahwa metode ini memiliki kinerja yang baik dalam aplikasi seperti segmentasi citra dan analisis data genetik [31].

E. Evaluasi Kualitas Clustering

Evaluasi terhadap hasil pengelompokan substrat dilakukan melalui dua pendekatan utama, yaitu evaluasi intrinsik dan evaluasi ekstrinsik. Evaluasi intrinsik digunakan untuk menilai kualitas partisi data secara mandiri tanpa menggunakan data acuan, yang dalam penelitian ini diukur menggunakan *Silhouette Score* dan *Davies-Bouldin Index (DBI)* dengan merujuk pada kriteria informativitas yang dijelaskan oleh [32]. Sementara itu, evaluasi ekstrinsik dilakukan untuk memvalidasi hasil *clustering* terhadap kondisi riil di lapangan (*ground truth*) dengan menghitung nilai *Overall Accuracy (OA)* dan *Kappa Coefficient* menggunakan data dari *Allen Coral Atlas (ACA)*.

1. Silhouette Score

Silhouette Score adalah metrik evaluasi internal yang mengukur tingkat kesamaan sebuah piksel dengan klasternya sendiri dibandingkan dengan kluster terdekat lainnya. Metrik ini menggabungkan aspek kohesi (kedekatan antar anggota dalam satu kluster) dan separasi (jarak antar kluster yang berbeda). Nilai *Silhouette* untuk satu titik data i dihitung dengan persamaan berikut [32].

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (10)$$

Dengan $a(i)$ merupakan rata-rata jarak titik i ke semua titik lain dalam kluster yang sama, dan $b(i)$ merupakan rata-rata jarak terkecil titik i ke semua titik di kluster lain yang berbeda.

Interpretasi nilai *silhouette score* berkisar antara -1 hingga +1. Nilai yang mendekati +1 menunjukkan bahwa piksel telah dikelompokkan dengan sangat baik dan terpisah jauh dari kluster lain, nilai mendekati 0 menunjukkan adanya tumpang tindih (*overlapping*) antar kluster, dan nilai negatif menunjukkan kemungkinan kesalahan penempatan piksel dalam sebuah kelompok [32].

2. Davies-Bouldin Index (DBI)

Davies-Bouldin Index (DBI) merupakan metrik yang menghitung rasio jumlah penyebaran di dalam kluster terhadap jarak pemisahan antar pusat kluster. DBI memberikan penilaian terhadap kemiripan rata-rata antara setiap kluster dengan kluster yang paling menyerupainya. Formula DBI didefinisikan sebagai berikut [32].

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{s_i + s_j}{M_{ij}} \right) \quad (11)$$

Dengan k menunjukkan jumlah klaster yang terbentuk, S_i , S_j menunjukkan jarak rata-rata antara titik-titik dalam klaster terhadap pusat klasternya (centroid), dan M_{ij} menunjukkan jarak antar pusat klaster i dan klaster j .

Semakin kecil nilai DBI (mendekati 0), maka kualitas *clustering* dianggap semakin baik karena menunjukkan tingkat kepadatan yang tinggi dan separasi yang jauh antar pusat klaster. Kelebihan DBI terletak pada kesederhanaan komputasinya serta efektivitasnya dalam menentukan jumlah klaster optimal pada data citra satelit yang memiliki variansi spektral yang tinggi [32].

3. Overall Accuracy (OA)

Overall Accuracy (OA) adalah metrik untuk mengukur proporsi piksel yang diklasifikasikan dengan benar dibandingkan dengan total keseluruhan piksel sampel. OA didefinisikan sebagai nilai rata-rata probabilitas bahwa sebuah piksel dipilih secara acak dari peta dan memiliki label yang sama dengan data referensi di lapangan [33]. Dalam konteks pemetaan pesisir, OA memberikan gambaran cepat mengenai efektivitas algoritma dalam membedakan objek benthos secara umum [34]. Secara matematis, nilai OA dihitung berdasarkan elemen diagonal pada matriks kesalahan (*error matrix*) menggunakan formula sebagai berikut [23].

$$OA = \frac{\sum_{i=1}^k x_{ii}}{N} \quad (12)$$

Dengan x_{ii} menunjukkan jumlah piksel pada baris i dan kolom i (diagonal) yang menunjukkan kesesuaian antara hasil *clustering* dan referensi, dan N menunjukkan total jumlah piksel sampel yang dievaluasi.

Interpretasi OA dinyatakan dalam bentuk persentase 0 - 100%. Semakin tinggi nilai persentase, semakin besar tingkat kecocokan antara hasil *clustering* dengan peta acuan.

4. Kappa Coefficient

Kappa coefficient (κ) merupakan metrik yang mengukur tingkat kesepakatan antara hasil klasifikasi citra dengan data referensi dengan mempertimbangkan faktor kebetulan (*chance agreement*). Kappa memberikan evaluasi yang lebih ketat dibandingkan OA karena metrik ini memperhitungkan seluruh elemen dalam matriks kesalahan, termasuk *error of omission* dan *error of commission* [23]. Kappa sangat penting untuk menghindari bias interpretasi pada wilayah dengan luas kelas benthos yang tidak seimbang [33]. Secara matematis, Kappa coefficient dihitung menggunakan formula sebagai berikut.

$$\kappa = \frac{N \sum_{i=1}^k x_{ii} - \sum_{i=1}^k (x_{i+} \cdot x_{+i})}{N^2 - \sum_{i=1}^k (x_{i+} \cdot x_{+i})} \quad (13)$$

Dengan N menunjukkan total jumlah piksel sampel, x_{ii} menunjukkan jumlah piksel yang benar (diagonal), x_{i+} menunjukkan total jumlah piksel pada baris i (total hasil *clustering* per kelas), dan x_{+i} menunjukkan total jumlah piksel pada kolom i (total data referensi per kelas).

Interpretasi nilai Kappa berkisar antara -1 hingga 1. Berdasarkan [33], nilai $> 0,8$ menunjukkan kesepakatan yang sangat kuat, $0,40-0,80$ menunjukkan kesepakatan moderat, dan nilai $< 0,40$ menunjukkan kesepakatan yang buruk.

F. Analisis Spasio-Temporal dan Change Detection

1. Deteksi Perubahan

Deteksi perubahan (*change detection*) didefinisikan sebagai proses untuk mengidentifikasi perbedaan keadaan suatu objek atau fenomena melalui observasi pada waktu yang berbeda. Dalam penginderaan jauh, prinsip deteksi perubahan didasarkan pada asumsi bahwa perubahan penggunaan atau tutupan lahan akan mengubah perilaku spektral (nilai reflektansi atau tekstur lokal) yang dapat dibedakan dari pengaruh faktor luar seperti kondisi atmosfer atau iluminasi matahari [35].

2. Post-Classification Comparison (PCC)

Metode *Post-Classification Comparison* (PCC) merupakan teknik kuantitatif yang membandingkan dua citra yang telah diklasifikasikan secara independen untuk menghasilkan matriks perubahan “dari-mana-ke-mana” (*from-to change*) [35]. Untuk memastikan validitas perbandingan, citra multi-temporal harus melalui tahap rektifikasi geometris terlebih dahulu guna menjamin koordinat piksel (x,y)(x,y) pada kedua citra saling berhimpitan secara presisi [35]. Setelah proses rektifikasi terpenuhi, setiap citra diklasifikasikan secara terpisah menggunakan skema kelas dan parameter yang identik sebelum dilakukan tahap komparasi.

2.2 Penelitian Terdahulu

TABEL I
TABEL PERBANDINGAN LITERATUR

No	Penulis	Tujuan Penelitian	Metode	Data & Sumber	Lokasi	Relevansi dengan Penelitian Ini
1	Barve et al. (2023) [16]	Mengembangkan framework Reef-Insight untuk membandingkan metode clustering unsupervised dalam pemetaan habitat terumbu karang	K-Means, GMM, Agglomerative, DBSCAN	Sentinel-2, WorldView	Great Barrier Reef, Australia	Acuan utama framework clustering; penelitian ini menambahkan OPTICS, Spectral, dan dimensi multitemporal


2	Petus et al. (2025) [36]	Mengembangkan monitoring terumbu karang otomatis berbasis time-series tanpa data latih	PCA + K-Means + DII (Lyzenga)	Sentinel-2 (GEE)	New Caledonia	Acuan penggunaan PCA dan DII untuk koreksi kedalaman serta alur unsupervised
3	Roelfsema et al. (2022) [37]	Review pendekatan ML untuk pemetaan dan monitoring habitat terumbu karang	Review (PBCD, OBCD, ML)	Multi-sensor (review)	Global	Justifikasi penggunaan PCC dan pendekatan unsupervised tanpa data latih
4	Zhou et al. (2018) [38]	Membandingkan metode change detection (OBCD vs PBCD) untuk habitat terumbu karang	PBCD, OBCD + Random Forest	QuickBird, WorldView-2	Laut Cina Selatan	Acuan change detection; penelitian ini mengadaptasi PCC pada Sentinel-2
5	Kennedy et al. (2020) [4]	Menganalisis perubahan komunitas terumbu karang di Karimunjawa sebelum dan sesudah bleaching	Survei in-situ + analisis multivariat	Data lapangan + citra satelit	Karimunjawa, Indonesia	Referensi baseline ekosistem dan perubahan substrat bentik
6	Munasik et al. (2025) [3]	Mendokumentasikan dampak bleaching GCBE 2023–2024 di Karimunjawa	Survei in-situ	Data lapangan	Karimunjawa, Indonesia	Dasar penentuan periode T1 dan T2 serta validasi kejadian bleaching
7	Razak et al. (2025) [39]	Menganalisis bleaching dan pemulihan terumbu karang urban di Indonesia	Survei in-situ	Data lapangan	Kepulauan Seribu, Indonesia	Pembandingan konteks bleaching; menunjukkan keterbatasan survei lapangan
Penelitian ini		Mengintegrasikan 6 metode clustering unsupervised dalam change detection multitemporal untuk deteksi perubahan substrat bentik	PCA+K-Means,GMM, DBSCAN, OPTICS, Agglomerative, Spectral +PCC	Sentinel-2A (GEE) + Allen Coral Atlas	Karimunjawa, Indonesia	

Sejauh pengetahuan penulis, penelitian terkait pemanfaatan clustering multitemporal untuk analisis perubahan substrat bentik berbasis citra satelit resolusi tinggi, khususnya dengan integrasi data Sentinel-2A dan referensi global seperti Allen Coral Atlas (ACA), belum pernah dilakukan dalam studi kasus Karimun Jawa. Oleh karena itu, penelitian ini memberikan kontribusi melalui pengkajian metode clustering yang optimal serta evaluasi kesesuaiannya terhadap data referensi global dalam memetakan dinamika substrat bentik, dengan fokus pada wilayah Karimunjawa sebagai lokasi studi.

2.3 Kerangka Penelitian

Permasalahan utama dalam penelitian ini adalah belum adanya model pemetaan substrat bentik terumbu karang secara multitemporal di Karimun Jawa, belum dilakukannya integrasi metode analisis untuk mendeteksi perubahannya,

serta belum adanya evaluasi perbandingan metode *clustering* yang optimal. Oleh karena itu, penelitian ini mengusulkan pendekatan penginderaan jauh berbasis citra Sentinel-2A dengan mengintegrasikan enam metode *clustering unsupervised*, yaitu K-Means, GMM, DBSCAN, OPTICS, *Agglomerative*, dan *Spectral Clustering*, dengan *Post-Classification Comparison* (PCC) untuk mendeteksi perubahan substrat bentik akibat *bleaching* El Niño 2023–2024. Variabel yang digunakan adalah band citra B2, B3, B4, serta indeks DII(B2–B3) dan DII(B2–B4). Evaluasi dilakukan secara intrinsik menggunakan *Silhouette Score* dan *Davies-Bouldin Index*, serta secara ekstrinsik menggunakan *Overall Accuracy* dan *Kappa Coefficient* berbasis Allen Coral Atlas (ACA) sebagai *ground truth*. Hasil akhir divisualisasikan dalam bentuk *Change Detection Map* dan *Web Story Map*. Gambar 1 menunjukkan ilustrasi kerangka pikir penelitian ini.



Gambar 1. Kerangka Penelitian

III. METODOLOGI PENELITIAN

Penelitian ini menggunakan metode *Cross-Industry Standard Process for Data Mining* (CRISP-DM). CRISP-DM terdiri dari 6 tahapan yaitu Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation dan Deployment [40].

5.1 Business Understanding

Permasalahan utama penelitian ini adalah dampak anomali suhu akibat *El Niño* 2023 yang mengancam keberlangsungan ekosistem terumbu karang di Kepulauan Karimunjawa. Mengingat keterbatasan survei in-situ yang memakan waktu dan biaya, diperlukan metode pemantauan berbasis penginderaan jauh yang mampu mengidentifikasi perubahan substrat bentik secara otomatis dan spasial.

5.2 Data Understanding

a) Pengumpulan Data

Data yang digunakan dalam penelitian ini meliputi data utama berupa citra satelit multitemporal serta data referensi yang digunakan untuk mengevaluasi tingkat akurasi hasil klasifikasi.

Nama	Sumber	Periode	Refrensi
Sentinel - 2A	Website Google Earth Engine (GEE) https://earthengine.google.com/	Periode I: Okt - Nov 2023 Periode II: Feb - Mar 2024	[16]
ACA Benthic Map	Website Allen Coral Atlas (ACA) https://allencoralatlas.org/	Peta terbaru	[41]

5.3 Data Preparation

a) Deteksi awan

Proses penyaringan citra berdasarkan tingkat tutupan awan sangat penting untuk menjamin efisiensi penyimpanan serta transmisi data. Penggunaan *cloud mask* dalam tahap *pra pemrosesan* menjadi instrumen krusial untuk mengoptimalkan pemanfaatan area bebas awan pada citra Sentinel-2A. Hal ini secara langsung meningkatkan keandalan estimasi reflektansi bentik serta konsistensi hasil pemetaan substrat terumbu karang secara multitemporal [42]

b) NDWI

Normalized Difference Water Index (NDWI) digunakan pada tahap *pra pemrosesan* untuk mengekstraksi dan memisahkan area perairan dari non-perairan pada citra Sentinel-2A, sehingga analisis substrat bentik hanya dilakukan pada piksel yang benar-benar berada di kolom air[43].

c) Composite median

Pendekatan median composite ini bertujuan mengurangi pengaruh pengamatan berkualitas buruk seperti awan tipis, bayangan awan, dan haze yang masih tersisa setelah cloud masking [44], sekaligus menekan noise temporal tanpa terlalu menghaluskan informasi spektral substrat bentik yang penting bagi pemisahan kelas karang hidup, karang mati, lamun, dan pasir.

5.4 Modeling

Proses pemodelan dalam penelitian ini dilakukan dalam dua tahap utama. Tahap pertama adalah pemodelan kelas substrat bentik dengan unsupervised learning menggunakan enam algoritma clustering, yaitu K-Means, Gaussian Mixture Model (GMM), DBSCAN, OPTICS, Agglomerative Clustering (AGNES), dan Spectral Clustering, yang diterapkan pada fitur spektral dan indeks

kedalaman-invarian (DII) hasil prapemrosesan citra Sentinel-2A multitemporal.

Tahap kedua adalah analisis performa model dan pemilihan algoritma terbaik untuk pemetaan perubahan substrat bentik. Pada tahap ini, hasil clustering dari masing-masing algoritma dikonversi menjadi kelas substrat bentik tematik (karang hidup, karang mati/puing, lamun/makroalga, pasir) kemudian dibandingkan menggunakan metrik akurasi spasial berupa confusion matrix, overall accuracy, dan koefisien Kappa. Selain itu, dilakukan evaluasi kualitatif terhadap pola spasial peta yang dihasilkan (misalnya kesesuaian zonasi reef flat, reef slope, dan lagoon), serta konsistensinya terhadap kronologi dampak El Niño yang dilaporkan pada studi sebelumnya, sehingga algoritma yang dipilih tidak hanya memiliki akurasi statistik tertinggi tetapi juga paling konsisten secara ekologis dalam merepresentasikan dinamika perubahan substrat bentik terumbu karang. Model terbaik akan divalidasi dengan *ground check* menggunakan data referensi dari Allen Coral Atlas.

5.5 Evaluation

Tahap evaluasi dalam penelitian ini bertujuan untuk menilai kinerja enam algoritma clustering dalam memetakan substrat bentik terumbu karang serta mengukur konsistensi spasial peta perubahan yang dihasilkan. Evaluasi dilakukan melalui pendekatan multi-metrik yang dibagi menjadi dua kelompok utama, yaitu metrik kualitas clustering internal untuk menilai pemisahan klaster di ruang fitur, serta metrik akurasi spasial berbasis data referensi luar. Penggunaan metrik internal seperti Silhouette Score, Calinski–Harabasz Index, dan Davies–Bouldin Index menjadi krusial untuk mengevaluasi struktur klaster tanpa bergantung pada data label. Silhouette Score mengukur sejauh mana sebuah piksel lebih dekat ke klasternya sendiri dibanding klaster lain, sementara Davies–Bouldin Index menilai rata-rata kemiripan antar-klaster di mana nilai yang lebih rendah mengindikasikan pemisahan yang lebih baik. Pendekatan ini selaras dengan praktik evaluasi pada algoritma seperti K-Means dan DBSCAN untuk memastikan bahwa klaster yang terbentuk secara statistik memiliki kohesi dan separasi yang optimal pada data citra satelit spasio-temporal.

Selanjutnya, dilakukan evaluasi akurasi spasial eksternal dengan membandingkan hasil pemodelan yang telah dilabeli (seperti kelas karang hidup, karang mati, lamun, dan pasir) terhadap data referensi dari Allen Coral Atlas (ACA) serta data lapangan. Melalui penggunaan confusion matrix, dihitung nilai Overall Accuracy (OA), Producer’s Accuracy (PA), User’s Accuracy (UA), serta koefisien Kappa untuk mengukur tingkat kesesuaian tematik. Berdasarkan literatur pemetaan habitat bentik menggunakan Sentinel-2A, nilai OA di atas 80% dan Kappa $\geq 0,6$ dianggap memadai untuk menjamin keandalan analisis perubahan habitat secara multitemporal. Evaluasi ini juga mencakup penilaian konsistensi terhadap kelas-kelas campuran seperti rubble, pasir, dan alga yang seringkali

memiliki karakteristik spektral yang tumpang tindih. Selain pengujian numerik, aspek visual dan konsistensi ekologis menjadi parameter penting dalam menentukan model terbaik. Hasil klasifikasi dan peta perubahan akan di-overlay dengan komposit warna asli Sentinel-2A untuk menilai apakah sebaran kelas substrat konsisten dengan zonasi geomorfik terumbu karang, seperti area reef flat, lagoon, dan reef slope. Pola transisi substrat, khususnya penurunan tutupan karang hidup yang diikuti peningkatan karang mati atau alga pasca El Niño, divalidasi dengan informasi dampak termal dari literatur untuk memastikan hasil pemodelan masuk akal secara biologis. Melalui kombinasi metrik internal, akurasi spasial, dan validasi ekologis ini, algoritma dengan performa paling stabil akan dipilih sebagai basis dalam menguantifikasi dampak El Niño 2023 di wilayah studi secara komprehensif.

5.6 Deployment

Tahap ini melibatkan pembuatan webstory berdasarkan hasil penelitian yang dibangun menggunakan framework React.js sebagai artefak visualisasi interaktif untuk menyajikan peta perubahan substrat bentik terumbu karang akibat El Niño. React merupakan kerangka kerja open-source yang dikembangkan oleh Meta (Facebook) dan banyak digunakan untuk membangun antarmuka pengguna berbasis komponen yang modular, sehingga mendukung pengembangan aplikasi web yang efisien, terstruktur, dan mudah dipelihara. Pendekatan berbasis komponen ini memungkinkan integrasi elemen-elemen visual seperti peta interaktif, grafik waktu perubahan luas karang hidup, dan panel informasi tekstual dalam satu alur cerita yang responsif dan dapat diakses melalui berbagai perangkat

DAFTAR PUSTAKA

- [1] F. Shabani, M. Raie, and K. Kabiri, “Deep-Sea Research Part II ~ o Studying the impact of sea surface temperature (SST) changes and El Ni n phenomenon on coral reefs bleaching around Kish Island in the northern Persian Gulf : A remote sensing approach,” *Deep. Res. Part II*, vol. 224, no. September, p. 105550, 2025, doi: 10.1016/j.dsr2.2025.105550.
- [2] NOAA, “Shallow Coral Reef Habitat.” [Online]. Available: <https://www.fisheries.noaa.gov/national/habitat-conservation/shallow-coral-reef-habitat>
- [3] E. Science, “Rapid assessment of coral bleaching induced by 2023 ENSO in Karimunjawa , Central Java Rapid assessment of coral bleaching induced by 2023 ENSO in Karimunjawa , Central Java,” 2023, doi: 10.1088/1755-1315/1496/1/012029.
- [4] E. V Kennedy *et al.*, “Coral Reef Community Changes in Karimunjawa National Park ,

- Indonesia : Assessing the E ffi cacy of Management in the Face of Local and Global Stressors,” 2020.
- [5] B. L. Spady *et al.*, “The 4th global coral bleaching event : ushering in an era of near - annual bleaching,” *Coral Reefs*, 2026, doi: 10.1007/s00338-025-02810-x.
- [6] S. Aulia, R. Tarigan, and D. P. Wijayanti, “Dynamic of coral recruits in the Karimunjawa National Park , Central Java , Indonesia,” vol. 25, no. 2, pp. 869–880, 2024, doi: 10.13057/biodiv/d250247.
- [7] E. D. Satya, A. Sabdon, D. P. Wijayanti, and M. Helmi, “Mapping coral cover using Sentinel-2A in Karimunjawa , Indonesia,” vol. 24, no. 2, pp. 827–836, 2023, doi: 10.13057/biodiv/d240219.
- [8] J. Xu, J. Zhao, F. Wang, Y. Chen, Z. Lee, and E. J. Hochberg, “Detection of Coral Reef Bleaching Based on Sentinel-2 Multi-Temporal Imagery : Simulation and Case Study,” vol. 8, no. March, pp. 1–15, 2021, doi: 10.3389/fmars.2021.584263.
- [9] D. Souter, S. Planes, J. Wicquart, M. Logan, D. Obura, and F. Staub, *Status of Coral Reefs of the World : 2020*. Global Coral Reef Monitoring Network (GCRMN), International Coral Reef Initiative (ICRI), 2020. doi: 10.59387/WOTJ9184.
- [10] S. Yang, Z. Li, J. Yu, X. Hu, and W. Dong, “Oscillation and its impact in the changing climate,” pp. 840–857, 2018, doi: 10.1093/nsr/nwy046.
- [11] J. P. Sudarto, S. H. Tembalang, and T. Fax, “Online di : <http://ejournal-s1.undip.ac.id/index.php/jose> STUDI PENGARUH EL NINO SOUTHERN OSCILLATION (ENSO) DAN INDIAN OCEAN DIPOLE (IOD) TERHADAP VARIABILITAS SUHU PERMUKAAN LAUT DAN KLOOROFIL-A DI PERAIRAN KARIMUNJAWA Abdal Seprianto , Kunarso , Anindya Wirasatriya Program Studi Oseanografi , Fakultas Perikanan Dan Ilmu Kelautan , Universitas Diponegoro,” vol. 5, pp. 452–461, 2016.
- [12] G. Liu *et al.*, “NOAA Coral Reef Watch ’ s Next - Generation 5 km Satellite Coral Bleaching Thermal Stress Monitoring,” vol. 29, no. 2, pp. 27–29, 2014.
- [13] B. Reef, “Geophysical Research Letters,” pp. 601–607, 2017, doi: 10.1002/2017GL074877.
- [14] S. Abrar, Muhammad; Bengen, Dietrich G.; Zamani, Neviaty P.; Suharsono; Putra, Risandi Dwirama; Sari, Ni Wayan Purnama; Siringoringo, Rikoh M.; Hadi, Tri Aryono; Giyanto; Sutiadi, Raden; Faricha, Ana; Ilham, Yuwanda; Salatalohi, Abdullah; Wouthuyzen, “Spatio-temporal juvenile corals (Scleractinia) following the 2016 coral bleaching event at the Pieh Islands Marine Tourism Park (PIMTP), West Sumatra Province, Indonesia,” *Reg. Stud. Mar. Sci.*, vol. 75, p. 103533, 2024.
- [15] M. A. Z. Fuad and U. Brawijaya, “Jurnal Pendidikan Geografi : Kajian , Teori , dan Praktek dalam Bidang Pendidikan dan Ilmu Geografi Pemetaan terumbu karang dengan citra satelit Sentinel-2 dan analisis kondisi karang di kawasan Pantai Pasir Putih , Situbondo Jawa Timur Pemetaan terumbu karang dengan citra satelit Sentinel-2 dan analisis kondisi karang di kawasan Pantai Pasir Putih , Situbondo Jawa Timur,” vol. 27, no. 1, 2024, doi: 10.17977/um017v27i12022p73-87.
- [16] S. Barve, J. M. Webster, and R. Chandra, “Reef-Insight : A Framework for Reef Habitat Mapping with Clustering Methods Using Remote Sensing,” pp. 1–16, 2023.
- [17] N. Gorelick, M. Hancher, M. Dixon, S. Ilyushchenko, D. Thau, and R. Moore, “Remote Sensing of Environment Google Earth Engine : Planetary-scale geospatial analysis for everyone,” *Remote Sens. Environ.*, vol. 202, pp. 18–27, 2017, doi: 10.1016/j.rse.2017.06.031.
- [18] Z. Zhu and C. E. Woodcock, “Remote Sensing of Environment Object-based cloud and cloud shadow detection in Landsat imagery,” *Remote Sens. Environ.*, vol. 118, pp. 83–94, 2012, doi: 10.1016/j.rse.2011.10.028.
- [19] D. Traganos and P. Reinartz, “Mapping Mediterranean seagrasses with Sentinel-2 imagery,” *Mar. Pollut. Bull.*, vol. 134, no. July 2017, pp. 197–209, 2018, doi: 10.1016/j.marpolbul.2017.06.075.
- [20] P. Taylor and S. K. Mcfeeters, “International Journal of Remote Sensing The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features,” no. November 2013, pp. 37–41, 2007, doi: 10.1080/01431169608948714.
- [21] L. David R, “Passive Remote Sending Techniques For Mapping Water Depth and Bottom Features,” 1978.
- [22] F. Immordino, M. Barsanti, E. Candigliota, S. Cocito, I. Delbono, and A. Peirano, “Application of Sentinel-2 Multispectral Data for Habitat Mapping

- of Pacific Islands : Palau Republic (Micronesia , Pacific Ocean),” 2019.
- [23] J. A. Richards and A. Introduction, *Remote Sensing Digital Image Analysis*.
- [24] J. Macqueen, “SOME METHODS FOR CLASSIFICATION AND ANALYSIS OF MULTIVARIATE OBSERVATIONS,” vol. 233, no. 233, pp. 281–297.
- [25] F. Murtagh and P. Contreras, “Algorithms for hierarchical clustering : an overview,” vol. 00, no. February, pp. 1–4, 2011, doi: 10.1002/widm.53.
- [26] L. A. F. B. JoE H. WARD, JR. Aerospace Medical Division and A, “HIERARCHICAL GROUPING TO OPTIMIZE AN OBJECTIVE FUNCTION,” vol. 58, no. 301, pp. 236–244, 2010.
- [27] L. Rokach and O. Maimon, “Minkowski : Distance Measures for Numeric Attributes”.
- [28] M. Ester, H. Kriegel, X. Xu, and D.- Miinchen, “A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise,” 1996.
- [29] M. Ester, “DBSCAN Revisited , Revisited : Why and How You Should (Still) Use DBSCAN,” vol. 42, no. 3, 2017.
- [30] B. Au, “Spectral Graph Clustering,” pp. 1–12, 2007.
- [31] R. Mondal, E. Ignatova, D. Walke, D. Broneske, G. Saake, and R. Heyer, “Clustering graph data : the roadmap to spectral techniques,” *Discov. Artif. Intell.*, no. January, 2024, doi: 10.1007/s44163-024-00102-x.
- [32] D. Chicco, A. Campagner, A. Spagnolo, D. Ciucci, and G. Jurman, “The Silhouette coef fi cient and the Davies-Bouldin index are more informative than Dunn index , Calinski-Harabasz index , Shannon entropy , and Gap statistic for unsupervised clustering internal evaluation of two convex clusters,” 2025, doi: 10.7717/peerj-cs.3309.
- [33] K. G. Russell G. Congalton, *Assessing the Accuracy of Remotely Sensed Data*. 2009.
- [34] P. J. M. A. J. E. and C. D. C. Edmund P. Green, *REMOTE SENSING handbook for Tropical Coastal Management*. 2000.
- [35] M. Hussain, D. Chen, A. Cheng, H. Wei, and D. Stanley, “ISPRS Journal of Photogrammetry and Remote Sensing Change detection from remotely sensed images : From pixel-based to object-based approaches,” *ISPRS J. Photogramm. Remote Sens.*, vol. 80, pp. 91–106, 2013, doi: 10.1016/j.isprsjprs.2013.03.006.
- [36] Z. Alzayer, P. Mason, and R. Platt, “An Improved Machine Learning-Based Method for Unsupervised Characterisation for Coral Reef Monitoring in Earth Observation Time-Series Data,” pp. 1–23, 2025.
- [37] J. D. Hedley *et al.*, “Remote Sensing of Coral Reefs for Monitoring and Management : A Review,” 2016, doi: 10.3390/rs8020118.
- [38] Z. Zhou, L. Ma, T. Fu, G. Zhang, and M. Yao, “Change Detection in Coral Reef Environment Using High-Resolution Images : Comparison of Object-Based and Pixel-Based Paradigms,” 2018, doi: 10.3390/ijgi7110441.
- [39] T. B. Razak *et al.*, “Coral Bleaching and Recovery on Urban Reefs off Jakarta , Indonesia , During the 2023 – 2024 Thermal Stress Event,” pp. 1–9, 2025.
- [40] P. Chapmen, *CRISP-DM 1.0: Step-by-step data mining guide*. 2000.
- [41] G. A. Trudeau, K. Lowell, and J. A. Dijkstra, “Coral reef detection using ICESat-2 and machine learning,” vol. 87, no. February, 2025.
- [42] N. Notarangelo, C. Wirion, and F. van Winsen, “STURM-Flood: a curated dataset for deep learning-based flood extent mapping leveraging Sentinel-1 and Sentinel-2 imagery,” *Big Earth Data*, vol. 9, no. 3, pp. 412–438, 2025, doi: 10.1080/20964471.2025.2458714.
- [43] W. Jiang *et al.*, “An Effective Water Body Extraction Method with New Water Index for Sentinel-2 Imagery,” 2021.
- [44] D. Simonetti, U. Pimple, A. Langner, and A. Marelli, “Pan-tropical Sentinel-2 cloud-free annual composite datasets,” *Data Br.*, vol. 39, p. 107488, 2021, doi: 10.1016/j.dib.2021.107488.